

Aplicación de algoritmos adaptativos y detección del *drift* para la predicción del cierre del IBEX-35



Sergi Payarol Calzado

Máster Universitario en Ciencia de Datos

Data Analytics in Industrial and Business
Environments

Jesús Lopez Lobo
Susana Acedo Nadal

8 de enero de 2025

Universitat Oberta
de Catalunya



Esta obra está sujeta a una licencia de Reconocimiento-
NoComercial-SinObraDerivada [3.0 España de Creative Commons](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)

Ficha del Trabajo Final

Título del trabajo:	Aplicación de algoritmos adaptativos y detección del <i>drift</i> para la predicción del cierre del IBEX-35
Nombre del autor/a:	Sergi Payarol Calzado
Nombre del Tutor/a de TF:	Jesús Lopez Lobo
Nombre del/de la PRA:	Susana Acedo Nadal
Fecha de entrega:	01/2025
Titulación o programa:	Máster Universitario en Ciencia de Datos
Área del Trabajo Final:	Data Analytics in Industrial and Business Environments
Idioma del trabajo:	Castellano
Palabras clave	Algoritmos adaptativos, <i>Concept drift</i> , Estrategia de inversión
Código fuente:	https://github.com/SergiPayarol/online_machine_learning_IBEX_35

Resumen del Trabajo

En el ámbito de las finanzas y la inversión cada segundo cuenta, debido a la actualización constante de los datos que se ven influenciados por las dinámicas globales y macroeconómicas. Los índices bursátiles, como el IBEX-35 son monitoreados por miles de inversores, y sus valores de cierre juegan un papel clave en la toma de decisiones fundamentados en su estrategia de inversión. Sin embargo, predecir el comportamiento de estos índices presenta un reto significativo debido a su alta volatilidad, causada por múltiples factores que pueden desactualizar rápidamente los modelos predictivos.

Este trabajo aborda este desafío mediante el uso de algoritmos adaptativos, con un énfasis particular en la detección del *drift*, es decir, cambios repentinos en los datos que pueden afectar la precisión de los modelos. El objetivo es identificar y actualizar en tiempo real el modelo predictivo, adaptándolo a las nuevas condiciones del mercado para así poder predecir adecuadamente el cierre del IBEX-35.

A partir de una investigación exhaustiva, se ha identificado diversas variables exógenas relevantes que podrían influir en la evolución del índice. Para modelar el comportamiento de los índices, se empleará modelos de series temporales de la librería River para así poder captar patrones no lineales y secuenciales en los datos.

Por último, se verá que, de los modelos implementados, el modelo SNARIMAX univariado con monitoreo de *drift* mediante ADWIN ha mostrado una alta precisión en la predicción del cierre del IBEX-35, con un R^2 de 0.996 y un MAPE del 1.224%.

Abstract

In the field of finance and investment, every second counts due to the constant updating of data influenced by global and macroeconomic dynamics. Stock indices, such as the IBEX-35, are monitored by thousands of investors, and their closing values play a key role in decision-making based on their investment strategy. However, predicting the behaviour of these indices presents a significant challenge due to their high volatility, caused by multiple factors that can quickly render predictive models outdated.

This work addresses this challenge through the use of adaptive algorithms, with a particular emphasis on drift detection, which refers to sudden changes in the data that can affect the accuracy of the models. The goal is to identify and update the predictive model in real-time, adapting it to the new market conditions to accurately predict the closing of the IBEX-35.

Based on thorough research, various relevant exogenous variables that could influence the index's evolution have been identified. To model the behaviour of the indices, time series models from the River library will be employed to capture non-linear and sequential patterns in the data.

Finally, among the implemented models, the univariate SNARIMAX model with drift monitoring using ADWIN has demonstrated high accuracy in predicting the IBEX-35 closing values, achieving an R^2 of 0.996 and a MAPE of 1.224%.

Índice

1.Introducción	1
1.1.Contexto y justificación del Trabajo	2
1.2.Objetivos del Trabajo	4
1.2.1 Objetivo principal	4
1.2.2 Objetivos secundarios	4
1.3.Impacto en sostenibilidad, ético-social y de diversidad	4
1.3.1 Dimensión de sostenibilidad	5
1.3.2 Dimensión de comportamiento ético y responsabilidad social	5
1.3.3 Dimensión de diversidad, género y derechos humanos	5
1.4.Enfoque y método seguido	5
1.4.1 Investigación	6
1.4.2 Preprocesamiento de los datos	6
1.4.3 Análisis de los datos	7
1.4.4 Aprendizaje en línea	8
1.5.Planificación del trabajo	8
2.Estado del arte	9
2.1 Algoritmos adaptativos	9
2.2 <i>Concept drift</i>	14
2.3 Factores que más influyen en el IBEX-35	18
2.4 Conclusiones	19
3.Materiales y métodos	20
3.1. Preprocesamiento	20
3.2 Análisis Exploratorio de los Datos	22
3.2.1 Las series temporales	22
3.2.2 Selección de variables	23
3.2.3 Análisis de las series temporales	26
3.3 Aprendizaje incremental	33
3.3.1 <i>Concept drift</i>	34
3.3.2 Indicadores estadísticos de los modelos	37
3.3.3 Modelos	39
4.Resultados	41

4.1 Selección de variables	41
4.2 Correlación cruzada	41
4.3 Variabilidad según el coeficiente de variación	42
4.4 Tendencia	43
4.5 Serie aditiva o multiplicativa	43
4.6 Estacionalidad	44
4.7 Autocorrelación (ACF y PACF)	44
4.7.1 Autocorrelación (ACF)	44
4.7.2 Autocorrelación Parcial (PACF)	45
4.8 Estacionariedad	45
4.9 Heterocedasticidad	46
4.10 Aprendizaje incremental	47
4.10.1 SNARIMAX_no_exo_si_adwin	47
4.10.2 SNARIMAX_no_exo_no_adwin	48
4.10.3 SNARIMAX_w3_no_adwin	48
4.10.4 SNARIMAX_w3_si_kswin	49
4.10.5 SNARIMAX_w3_si_adwin	49
4.10.6 SNARIMAX_w4_si_adwin	50
4.10.7 Holt_Winters_no_drift	50
5.Conclusiones y trabajos futuros	52
6.Glosario	54
7.Bibliografía	56
8.Anexos	60

Lista de Figuras

Figura 1: Ejemplo de serie no estacionaria. Realizado en R.....	31
Figura 2: Ejemplo de serie estacionaria. Realizado en R.....	31
Figura 3: Ejemplo de serie heterocedástica. Realizado en R.....	33
Figura 4: Resultados de la correlación cruzada.....	41

Lista de Tablas

Tabla 1: Planificación del trabajo.....	8
Tabla 2: Tabla resumen de la etapa de preprocesado.....	22
Tabla 3: Resultado del coeficiente de variación.....	42
Tabla 4: Resultados de la tendencia.....	43
Tabla 5: Resultados de si las series son multiplicativas o aditivas.....	44
Tabla 6: Resultados de estacionariedad. prueba Dickey Fuller	46
Tabla 7: Resultados de la heterocedasticidad. Pruebas de Pagan y White.	46
Tabla 8: Resultados de los modelos adaptativos.....	47
Tabla 9: Resultados de la selección de variables	60
Tabla 10: Resultados del Índice de Variancia Estacional.....	61

Lista de Códigos

Código 1: Configuración de ADWIN.	35
Código 2: Configuración de KSWIN.....	36
Código 3: Función para crear un modelo SNARIMAX.	60
Código 4: Configuración del algoritmo de Holt Winters.....	60

1. Introducció

El mercado financiero global se caracteriza por su alta volatilidad y su constante evolución, lo que presenta un desafío considerable para los inversores que buscan predecir tendencias y tomar decisiones de inversión informadas. Dentro de este contexto, la automatización y la inteligencia artificial (IA) han tomado un rol cada vez más central en la configuración de estrategias de *trading*, permitiendo a las gestoras de fondos, analistas y *traders* individuales optimizar el rendimiento de sus carteras. Entre las herramientas más destacadas, los algoritmos adaptativos se han convertido en una pieza fundamental para abordar la complejidad y la naturaleza dinámica de los mercados.

Este Trabajo Final de Máster tiene como objetivo principal predecir el valor de cierre del índice IBEX-35 mediante el uso de algoritmos adaptativos, con especial énfasis en la consideración del fenómeno del *concept drift*. Este fenómeno, que se refiere a la variación en la distribución de los datos subyacentes con el tiempo, representa un reto significativo para la creación de modelos predictivos robustos en entornos dinámicos como los mercados financieros. La capacidad de los algoritmos adaptativos para detectar y ajustarse a estos cambios en las relaciones entre las variables es crucial para mejorar la precisión y eficacia de las predicciones.

El uso de modelos predictivos en el ámbito del trading no es nuevo, pero la evolución de los datos y el aumento de la potencia computacional han llevado a una nueva generación de técnicas de aprendizaje automático que permiten a los inversores gestionar mejor los riesgos asociados a la volatilidad del mercado. Los algoritmos adaptativos, y en particular aquellos que incorporan técnicas de aprendizaje en línea, son capaces de actualizar sus parámetros a medida que reciben nuevos datos, lo que les permite ajustarse continuamente a las fluctuaciones del mercado en tiempo real.

Este trabajo también examinará el papel de estos algoritmos en el sector de la inversión, destacando sus beneficios para las gestoras de fondos y las empresas que ofrecen servicios de estrategia de inversión. En un entorno donde la velocidad de reacción a los cambios del mercado es vital, los algoritmos adaptativos permiten a las empresas optimizar recursos, mejorar la precisión de las decisiones de inversión y obtener análisis avanzados de carteras.

Estos análisis no solo facilitan la identificación de oportunidades de inversión, sino que también permiten gestionar el riesgo de forma más eficaz, maximizando la rentabilidad de las carteras bajo gestión.

Además, se explorarán las metodologías más avanzadas para la detección del *concept drift*, que es un desafío crítico para los modelos de predicción en finanzas. Cuando las relaciones históricas entre las variables cambian, ya sea por cambios estructurales en la economía, decisiones políticas o eventos imprevistos, como pandemias o crisis financieras, los modelos tradicionales pueden volverse obsoletos rápidamente. Al aplicar algoritmos adaptativos capaces de identificar y corregir estos desajustes, se puede asegurar que las predicciones permanezcan relevantes y precisas a lo largo del tiempo.

En resumen, este TFM se sitúa en la intersección entre el aprendizaje automático y la teoría financiera, con el objetivo de demostrar cómo la implementación de algoritmos adaptativos y la consideración del *concept drift* pueden mejorar las estrategias de predicción del IBEX-35. A través del uso de datos históricos del mercado y la aplicación de modelos avanzados, se pretende proporcionar un enfoque novedoso y eficaz para abordar los retos del trading en un entorno financiero que cambia rápidamente.

Este documento está estructurado de la siguiente manera. En primer lugar, se examina el rol de los algoritmos adaptativos en el sector de la inversión. Luego, se presenta el enfoque y los métodos seguidos, con un desglose del plan de trabajo. Posteriormente, se profundiza en los conceptos clave del proyecto, justificando el proceso seguido y los datos seleccionados en la sección de Materiales y Métodos. Finalmente, se presentan los resultados obtenidos, junto con unas conclusiones y reflexiones sobre posibles futuras líneas de trabajo a partir de los hallazgos de este proyecto.

A continuación, se contextualizará el trabajo y se detallará la justificación de su importancia.

1.1. Contexto y justificación del Trabajo

El *trading* tradicional se fundamenta en la capacidad de operar en los mercados financieros mediante un conocimiento sólido y experiencia, buscando así realizar inversiones seguras. Las decisiones de inversión se basan en estrategias que diversifican activos financieros, como acciones, bonos y derivados, para maximizar el rendimiento. Sin embargo, este

enfoque debe considerar múltiples factores que influyen en las cotizaciones, incluyendo tendencias globales como el cambio climático y movimientos geopolíticos, así como variables más específicas como los tipos de interés y la inflación. Con el auge del *trading* moderno, las decisiones de inversión se sustentan cada vez más en información generada por algoritmos avanzados. Y, con el aumento de capacidad de datos históricos, “el uso de *Big Data* en Bolsa es una inversión segura”, (IIC, 2024). De hecho, “el 80% del mercado de valores está ahora en piloto automático”, (Li, 2019).

En este contexto, los algoritmos adaptativos son útiles porque ajustan automáticamente sus parámetros en respuesta a estos cambios, lo que permite que las estrategias de inversión se mantengan relevantes en condiciones variables del mercado. A partir de estos ajustes, el algoritmo permite que los sistemas automáticos de *trading* detecten patrones emergentes o anomalías en los datos históricos y los nuevos datos en tiempo real. Esto es crucial para optimizar decisiones de inversión y minimizar el riesgo de pérdidas en momentos de alta volatilidad. Estos cambios en la distribución de los datos se conocen como *concept drift*. En el contexto de los mercados financieros, significa que las relaciones que existían entre variables como, por ejemplo, un conjunto de indicadores económicos y el valor de una acción, pueden cambiar con el tiempo debido a factores como crisis económicas o cambios regulatorios, como la bajada o subida de los tipos interés que puede determinar el BCE en Europa.

Intentar predecir el cierre del IBEX-35 puede ser una referencia clave para los inversores, ya que refleja el precio final de un activo en un día de negociación. Este dato es fundamental para evaluar la tendencia del mercado y la toma de decisiones de compra o venta. Por ejemplo, si el valor de cierre muestra una tendencia alcista, podría ser un indicativo de que los inversores están optimistas, lo que puede influir en decisiones estratégicas. Además, a partir de los valores de cierre, se pueden calcular métricas de rendimiento como el retorno sobre la inversión (ROI) y la volatilidad.

Por último, es importante exponer mi motivación para realizar este trabajo. Durante años, siempre me ha fascinado comprender y analizar el estado financiero y de inversión a nivel global. La evolución de las inversiones está intrínsecamente ligada a las dinámicas geopolíticas y económicas que influyen en el destino de los países. La historia, como registro del pasado, nos proporciona claves valiosas para interpretar el presente, y con datos sólidos

y confiables, es posible incluso anticipar tendencias futuras. Sin embargo, los índices de referencia, como el IBEX-35 en este caso, están fuertemente condicionados por estas dinámicas globales. Por ello, mi interés en analizar el *concept drift* y en actualizar modelos predictivos basados en eventos mundiales y múltiples variables exógenas surge de una motivación personal. Este estudio no solo me permitirá profundizar en la comprensión de estos fenómenos, sino también mejorar mi capacidad para interpretar y anticipar los cambios en los mercados financieros.

1.2. Objetivos del Trabajo

1.2.1 Objetivo principal

El objetivo principal del trabajo es implementar algoritmos adaptativos y analizar el *drift* para poder predecir el cierre del IBEX-53.

1.2.2 Objetivos secundarios

- Estudiar cómo los factores macroeconómicos influyen en el rendimiento del IBEX-35.
- Profundizar en el contexto del *concept drift* y aplicarlo a las series temporales de este proyecto.
- Implementar un modelo adaptativo y actualizarlo en tiempo real.
- Evaluar el desempeño de distintos modelos predictivos en escenarios de alta volatilidad.
- Optimizar el modelo predictivo mediante la integración de múltiples variables exógenas, mejorando su capacidad de adaptación a eventos inesperados.

1.3. Impacto en sostenibilidad, ético-social y de diversidad

Actuar de manera honesta, ética, sostenible, socialmente responsable y respetuosa con los derechos humanos y la diversidad, tanto en el ámbito académico como profesional, se enmarca dentro de la competencia de compromiso ético y global (CCEG), la cual se desglosa en tres dimensiones. En lo que respecta a los Objetivos de Desarrollo Sostenible (ODS) establecidos por las Naciones Unidas, podemos concluir que nuestro proyecto se alinea con el principio 9, que aboga por la industria, la innovación y la infraestructura.

1.3.1 Dimensión de sostenibilidad

Para este trabajo se hace uso de algoritmos adaptativos que ayudan a la toma de decisiones y ayudan a hacer más eficientes la optimización de la gestión de carteras del sector financiero, reduciendo el uso de recursos.

1.3.2 Dimensión de comportamiento ético y responsabilidad social

La investigación y el desarrollo del TFM abordan de manera integral los aspectos éticos y responsables en la creación de modelos de inversión, garantizando que las propuestas no promuevan prácticas inapropiadas ni infrinjan la privacidad o el manejo de datos personales. Es importante destacar que en este trabajo solo se utilizarán datos públicos. Asimismo, se tiene en cuenta el cumplimiento de los principios éticos establecidos en el ámbito financiero, en concordancia con el Objetivo de Desarrollo Sostenible (ODS) 8, que se centra en el trabajo digno y el crecimiento económico.

1.3.3 Dimensión de diversidad, género y derechos humanos

Este trabajo puede tener un impacto indirecto en la diversidad, el género y los derechos humanos, ya que se pueden entrenar modelos que exhiban sesgos si no se manejan cuidadosamente. No obstante, se integrarán criterios ESG (ambientales, sociales y de gobernanza) (Álvarez, C., 2024) en las estrategias de inversión, contribuyendo así a un enfoque más responsable que valore el impacto social y la equidad.

1.4. Enfoque y método seguido

Para este trabajo lo que se va a plantear es adaptar un producto existente y enfocarlo al IBEX-35. De hecho, ya hay estudios que analizan la predicción del mercado de valores basado en un algoritmo de entrenamiento adaptativo en aprendizaje automático (Kim, H., et al., 2022) y también se usan en empresas que realizan *trading* moderno como por ejemplo Bookmap (Bookmap, 2023).

La metodología empleada para el desarrollo de este proyecto seguirá un enfoque propio de la ciencia de datos. Partiremos de la recolección y preprocesado de datos de series temporales, a partir de los cuales se realizará un análisis exploratorio. Además, se aplicarán

métodos no supervisados para identificar patrones subyacentes y determinar los factores más relevantes en el estudio. Se prestará especial atención al análisis del *concept drift*, para evaluar si los factores recolectados permiten justificar los cambios en las series temporales.

Con los datos procesados, se procederá a la fase de implementación, donde se explorarán diversos algoritmos adaptativos y detección del *concept drift* y se desarrollará un modelo cuyo objetivo será predecir el valor de cierre del IBEX-35. Lo importante será evaluar el rendimiento del modelo, detectar posibles *drifts* y analizar si el modelo sigue adaptándose correctamente a nuevas circunstancias.

A continuación, se explicará cada tarea que se tendrá que realizar.

1.4.1 Investigación

La primera fase será la investigación. En este caso, se buscará información sobre los algoritmos adaptativos, centrándose especialmente en los disponibles en la librería River. También se profundizará en el concepto del *drift* para poder aplicarlo correctamente en el contexto del trabajo.

Además, se adentrará en el ámbito de las finanzas y la inversión para comprender mejor los factores que influyen en el comportamiento del IBEX-35.

Por último, se realizará una revisión del estado del arte en el ámbito del *trading* moderno, con énfasis en el uso de algoritmos adaptativos, para analizar los avances y enfoques actuales.

1.4.2 Preprocesamiento de los datos

Dentro de la fase de preprocesamiento de los datos se hará la extracción de los factores más influyentes que pueden afectar al IBEX-35, a partir de la información que se vaya recopilando en la fase de investigación. Una vez tengamos todos los datos, se procederá a hacer una lectura inicial de estos y estandarizarlos para agruparlos en un mismo DF.

1.4.3 Análisis de los datos

Una vez se tenga una base sólida de conocimientos y se hayan recopilado múltiples variables exógenas que puedan ayudar a predecir el valor de cierre del IBEX-35, procederemos al análisis de éstas junto a la serie temporal del índice.

Dado que se está trabajando con datos temporales, este análisis deberá tener en cuenta esta característica clave. Se tiene que tener en cuenta que “las series temporales son colecciones de observaciones que siguen un orden y tienen una secuencia en el tiempo” (Villavicencio, 2010). A lo largo del trabajo, se profundizará en estos conceptos en la sección Materiales y métodos. En esta fase, los componentes clave a analizar serán:

- Tendencia
- Estacionalidad
- Estacionariedad

Además, se realizarán otras pruebas estadísticas, tales como:

- Variabilidad de los datos
- Serie aditiva o multiplicativa
- Autocorrelación ACF y PACF
- Heterocedasticidad

Es importante destacar que la selección de variables será una de las principales tareas para así poder filtrar por los factores más relevantes de nuestro conjunto de datos. Para ello se usarán distintos métodos como el Análisis de Componentes Principales (PCA, por sus siglas en inglés). A partir de los valores de los índices, construiremos un conjunto de datos donde el tiempo será la primera columna y el resto serán los diferentes índices. Este enfoque permitirá una descomposición que ayude a identificar las variables más relevantes en términos de variabilidad explicada.

Con los resultados obtenidos en esta fase, seleccionaremos los algoritmos más adecuados para el proyecto. En este caso se usarán los algoritmos de SNARIMAX y Holt Winters.

1.4.4 Aprendizaje en línea

En esta fase, se utilizarán los algoritmos SARIMAX y Holt-Winters aplicando diferentes estrategias para evaluar cuál ofrece mejores resultados en términos de predicción. Se emplearán tanto métodos de predicción univariada como multivariada, adaptando los modelos según las características del problema y los datos disponibles. Además, en algunos casos, se tendrá en cuenta la monitorización del *concept drift*, con el fin de evaluar y ajustar los modelos frente a posibles cambios en los patrones de los datos a lo largo del tiempo.

Para medir el rendimiento de los modelos, se utilizará el MAE, MSE, RMSE, MAPE y R2.

1.5. Planificación del trabajo

A continuación, se presentará la planificación del trabajo para este proyecto:

TAREA	INICIO	FIN
Investigación		
Algoritmos adaptativos	25-9-24	14-10-24
<i>Concept drift</i>	25-9-24	14-10-24
IBEX-35	25-9-24	14-10-24
Factores que pueden influenciar al IBEX-35	25-9-24	14-10-24
Librería River	25-9-24	14-10-24
Estado del arte o análisis del mercado del proyecto	14-10-24	3-11-24
Preprocesamiento		
Extracción y preprocesado de los datos	15-10-24	27-10-24
Análisis Exploratorio de los datos		
Selección de variables	28-10-24	5-11-24
Análisis de las series temporales	6-11-24	14-11-24
Análisis del <i>concept drift</i>	15-11-24	17-11-24
Aprendizaje en línea		
Aprendizaje incremental con y sin monitoreo del <i>drift</i>	18-12-24	10-12-24
Evaluación del rendimiento de los modelos	10-12-24	23-12-24
Documentación	25-9-24	31-12-24

Tabla 1: Planificación del trabajo.

2. Estado del arte

En este apartado se profundizará en el papel de los algoritmos adaptativos y del *concept drift* en el mundo del *trading*. Para ello, nos basaremos en la recolección de documentación que se ha realizado en la etapa de investigación. Lo primero que nos interesa saber, es cuál es el papel de los algoritmos adaptativos en el campo de la inversión. Una vez se tenga claro su papel, se pasará a revisar cómo se trata el *concept drift*. Por lo tanto, se irá viendo qué métodos son los más interesantes y usados en la investigación y así poder contrastar la metodología del proyecto con trabajos académicos ya realizados. Por último, se analizarán qué factores son los más influyentes y que otros se han trabajado en la predicción del cierre del IBEX-35.

A continuación, se empezará hablando de los algoritmos adaptativos y de sus posibles usos en el mundo de la inversión.

2.1 Algoritmos adaptativos

Los algoritmos adaptativos se diseñan precisamente para enfrentar la necesidad de manejar grandes volúmenes de datos que se generan continuamente. Estos algoritmos permiten que los modelos se actualicen y ajusten automáticamente en respuesta a nuevos datos, haciéndolos más sostenibles y efectivos a lo largo del tiempo.

Los modelos pueden quedar obsoletos cuando la realidad en la que fueron entrenados cambia, ya que los nuevos datos pueden reflejar condiciones del mercado que el modelo no ha aprendido. Esto es particularmente relevante en el sector financiero y en el mercado de valores, donde la volatilidad puede afectar los valores liquidativos (NAV, por sus siglas en inglés) de los activos financieros. Si un modelo no se adapta o actualiza con los datos nuevos, puede ofrecer predicciones erróneas o ineficaces, poniendo en riesgo las decisiones basadas en esos datos, debido a la naturaleza altamente cambiante y sensible de la información financiera. De hecho, “la sucesión de manías, pánicos y caídas ha puesto de relieve la naturaleza no estacionaria y la probabilidad de cambios drásticos estructurales o conceptuales en los mercados” (Suárez, A., et al., 2019).

Es por ello, que “las metodologías de predicción del mercado de valores han ido evolucionando, particularmente en el campo del aprendizaje por refuerzo (RL, por sus siglas en inglés)” (Akhavanpour, M., 2024). A diferencia de los modelos tradicionales, que se limitan a predecir tendencias en los mercados, el RL permite una toma de decisiones más activa y dinámica. Este enfoque es interesante porque el agente no solo anticipa los movimientos del mercado, sino que también ajusta sus decisiones de compra o venta de acuerdo con las condiciones actuales del mercado y el resultado de decisiones anteriores.

Por lo tanto, podemos ver como el RL es útil para este tipo de tareas porque se basa en la interacción continua con el entorno. En el caso de los mercados financieros, el agente aprende mediante la experimentación, probando diferentes estrategias de inversión y recibiendo retroalimentación en forma de beneficios o pérdidas. Esto permite que el sistema se ajuste y se vuelva más eficiente a medida que cambia el mercado, algo que es crucial debido a la alta volatilidad e incertidumbre que caracterizan los mercados bursátiles.

Además, el uso de algoritmos adaptativos como el RL tiene una ventaja clave: la capacidad de adaptarse rápidamente a eventos inesperados o cambios estructurales en el mercado, conocidos como *concept drift*. En un mercado donde los factores externos (políticos, económicos o sociales) pueden cambiar radicalmente, contar con modelos que se ajusten automáticamente puede ser determinante para tomar decisiones de inversión más rentables.

Un ejemplo del uso del *Reinforcement Learning* (RL) es en el de la gestión de carteras. En *Deep Reinforcement Learning Agent for S&P 500 stock selection*, (Huotari, T., et al., 2020) nos explican como el DRL puede ayudar a mejorar en la detección y predicción de posibles anomalías en los datos y analiza el papel del *Deep Reinforcement Learning* (DRL, por sus siglas en inglés) en la gestión activa de carteras. De hecho, en este artículo nos cuentan cómo han intentado mejorar el método que se ha usado hasta ahora: la teoría moderna de carteras de Markowitz” (El, 2024). Esta teoría es un marco matemático para la creación de carteras de inversión optimizadas en función de su rentabilidad y riesgo. Se basa en los siguientes principios:

- Diversificación: Al combinar activos con diferentes correlaciones, el riesgo total de una cartera puede reducirse sin sacrificar la rentabilidad esperada.
- Rentabilidad esperada: Se calcula como el promedio ponderado de los rendimientos esperados de los activos que componen la cartera.

- Riesgo medido por la varianza: El riesgo se mide a través de la volatilidad (desviación estándar) de los rendimientos de la cartera.
- Frontera eficiente: Conjunto de carteras que ofrece la mayor rentabilidad posible para cada nivel de riesgo.
- Preferencias del inversor: La selección final depende de la aversión al riesgo del inversor, equilibrando entre riesgo y rentabilidad.

No obstante, el uso de los principios anteriores lleva a unas limitaciones que no permiten adelantarse a posibles anomalías del mercado. Para mejorar esta deficiencia, los autores usan un agente de *trading* automatizado basado en redes neuronales artificiales (ANN, por sus siglas en inglés) y aprendizaje por refuerzo para implementar estrategias en base a las predicciones de movimientos en el S&P500. En este estudio se hace hincapié en el uso de las ANN para detectar patrones y anomalías en los mercados financieros y en el RL. Es importante entender que, en el aprendizaje por refuerzo, los agentes aprenden a partir del ensayo y error para maximizar una función de recompensa, sin necesitar información previa sobre las mejores acciones. Uno de los procesos de decisión comúnmente usados son los Procesos de Decisiones de Markov (MDP, por sus siglas en inglés), donde las acciones no solo afectan a las recompensas inmediatas, sino también estados futuros. Una de las políticas usadas y descritas es la ecuación de Bellman, que permite encontrar la política óptima para cada estado a través de la función de valor óptima $v^*(s)$. En el caso de analizar el rendimiento del fondo, se ha usado la ratio de *Sharpe*. Esta ratio “es un indicador utilizado para medir la rentabilidad que ofrece una inversión en relación al riesgo que se asume con ella” (UNIR, 2022). Una ratio alta indica que una inversión tiene buena relación entre rentabilidad y riesgo, es decir, el inversor está obteniendo más rendimiento por unidad de riesgo asumido. Su fórmula es la siguiente:

$$\text{Ratio de Sharpe} = \frac{R_p - R_f}{\sigma_p}$$

Donde:

- R_p es la rentabilidad promedio del fondo de inversión
- R_f es la tasa libre de riesgo
- σ_p es la desviación estándar (volatilidad) de los retornos del fondo de inversión

Con todo esto, los autores pudieron desarrollar un agente capaz de generar su propia política de *trading*, lo que resultó en un rendimiento del 328.9% y una ratio *Sharpe* de 0.91 durante un periodo de cinco años, superando varios puntos de referencia de manera significativa en cuanto al rendimiento y la ratio *Sharpe*. Sin embargo, no se demostró que el modelo generado por el agente fuera estadísticamente distinto de cero frente al índice S&P 500, lo que sugiere que no superó al mercado de manera consistente. Además, al usar una red neuronal convolucional relativamente simple, mostró que los datos financieros históricos no son tan difíciles de manejar como otros tipos de datos más complejos, aunque la alta volatilidad del mercado puede haber afectado los resultados.

Además del DRL para la predicción del mercado de valores, también tenemos los algoritmos predictivos de series temporales. En *Stock Price prediction using adaptive time series forecasting and Machine Learning algorithms* Chen, (L., 2020) vemos como los algoritmos de *AutoRegressive Moving Average* (ARIMA, por sus siglas en inglés), Long Short-Term Memory (LSTM, por sus siglas en inglés) y *Extrem Gradient Boosting* (XGBoost, por sus siglas en inglés) pueden ser usados para la predicción del cierre de diferentes empresas como Amazon, Microsoft o Google. Hay que entender que en el trabajo de Chen se hace una aproximación univariada. Es decir, se ha usado una sola variable o característica a lo largo del tiempo para realizar predicciones futuras. En este caso, los datos históricos se centran únicamente en una serie de valores de una única variable (por ejemplo, los precios de cierre de una acción en el mercado de cada empresa), y la predicción se realiza exclusivamente sobre esa misma variable a partir de sus valores pasados.

Es interesante ver como este autor construye la base *adaptativa* del algoritmo a partir de la técnica *rolling forecast*. A través de esta técnica lo que se hace es reconstruir el modelo cada vez que se recibe un dato nuevo. Esto significa que se adapta a la nueva información y ajusta sus parámetros en consecuencia. De hecho, esta capacidad de recalibrar el modelo en respuesta a nuevas observaciones es la base de todo algoritmo adaptativo. Con el *rolling forecast* se itera a cada predicción en base a la historia de datos acumulada, lo que significa que el modelo se adapta continuamente a medida que se obtienen más datos. Para evaluar el error se hace uso del Error Cuadrático Medio (RMSE, por sus siglas en inglés) y el Error Absoluto Porcentual Medio (MAPE, por sus siglas en inglés), para así proporcionar retroalimentación sobre el rendimiento del modelo en cada iteración. Esta evaluación permite realizar ajustes adicionales, si es necesario, mejorando así la adaptabilidad del modelo. El

uso de diferentes modelos implica probar con diferentes maneras de predecir los datos. En este trabajo se muestra las diferencias y las funcionalidades de los tres algoritmos usados. Tenemos que entender que ARMA, LSTM y XGBoost son usados para la predicción de series temporales, pero con enfoques diferentes. ARMA es un modelo lineal que combina la autorregresión y el promedio móvil para capturar las relaciones lineales en datos temporales, siendo adecuado para series estacionarias. LSTM es una red neuronal recurrente diseñada para manejar secuencias largas y dependencias a largo plazo, capturando patrones no lineales y dinámicos en los datos. XGBoost, en cambio, es un modelo basado en árboles de decisión (*boosting*), que maneja tanto relaciones lineales como no lineales de forma eficiente, con alta capacidad de ajuste y flexibilidad, siendo ideal para datos estructurados y con ruido.

Un detalle importante es que los datos pueden tener un componente estacional. En este sentido, Chen analiza las series y determina como en algunas de ellas es mejor usar el modelo *Seasonal AutoRegressive Integrated Moving Average*, (SARIMA, por sus siglas en inglés). Este es una extensión del modelo ARIMA, que incorpora estacionalidad a los datos. Mientras que ARIMA maneja datos lineales y no estacionarios, SARIMA añade componentes que capturan los patrones repetitivos a intervalos regulares (estacionales). Se caracteriza por incluir parámetros adicionales que representan la periodicidad, lo que permite modelar mejores series temporales con fluctuaciones regulares en períodos como meses o estaciones del año.

A partir de los resultados de los modelos, Chen concluye que ARIMA y XGBoost tienen las mejores métricas, pero que XGBoost tiene un rendimiento computacional más bueno. Además, en el artículo se termina diciendo como “el factor más importante para la predicción del precio de hoy es el precio de ayer” (Chen, L., 2020).

Tal como se ha ido viendo, los algoritmos adaptativos se han usado en el contexto de las inversiones. Un aspecto clave que se engloba dentro de estos algoritmos es el papel del *concept drift*.

2.2 Concept drift

Como ya se ha comentado, el *concept drift* se refiere a la situación en la que la relación entre las variables de entrada y salida de un modelo cambia con el tiempo, lo que puede hacer que el modelo se vuelva menos preciso o incluso irrelevante.

“En muchos contextos, especialmente en finanzas y marketing, los datos son inherentemente dinámicos” (Gama et al., 2018). Por ejemplo, los patrones de comportamiento de los consumidores pueden cambiar debido a factores externos como tendencias económicas, cambios en la regulación, o nuevas tecnologías. Un algoritmo adaptativo necesita reconocer y ajustarse a estos cambios para seguir siendo efectivo. Es por eso que el desempeño del modelo va de la mano de la detección del *drift*. “Ya que los modelos que no consideran el *concept drift* pueden hacer predicciones erróneas, llevando a decisiones subóptimas. Los algoritmos adaptativos, por su diseño, permiten la actualización continua de los modelos a medida que llegan nuevos datos, manteniendo así la precisión de las predicciones” (Lu, J., et al. 2020). Es interesante ver como esta clase de algoritmos permiten mitigar el riesgo del sobreajuste al incorporar mecanismos que permiten reconocer y reaccionar al *concept drift*. Por ejemplo, un algoritmo puede priorizar los datos más recientes y relevantes mientras mantiene un registro de información histórica que puede seguir siendo valiosa. “Esto proporciona un balance entre recordar patrones anteriores y ser sensible a las nuevas tendencias, mejorando así la capacidad del modelo para generalizar a situaciones no vistas” (Hulten, G., et al., 2001).

Si se analiza más en detalle el *concept drift*, podemos entender que un conjunto de muestras sigue una cierta distribución a lo largo del tiempo, pero en un momento determinado $t + 1$, esta distribución cambia. Esto implica un cambio en la probabilidad conjunta denotado como:

$$P_t(X, y) \neq P_{t+1}(X, y)$$

Donde:

- X : son las características
- y : son las etiquetas

“Hay tres fuentes posibles de *concept drift*” (Lu, J., et al. 2020):

- Puede cambiar la distribución de características $P_t(X)$, pero la relación entre las características y las etiquetas $P_t(y|X)$ no cambia. Este tipo de *drift* no afecta directamente las predicciones del modelo y se denomina *drift virtual*.
- Puede cambiar la relación entre las características y las etiquetas $P_t(y|X)$, mientras que $P_t(X)$ se mantiene igual. Este tipo de *drift* sí que afecta a las fronteras de decisión del modelo y acaba afectando a la precisión.
- Hay un cambio simultaneo entre $P_t(y|X)$ y $P_t(X)$ donde acaba afectando al modelo.

Los mismos autores comentan que se puede agrupar en cuatro, los diferentes tipos de *concept drift*. Todo será en función de los cambios que se manifiestan en los resultados:

- *Drift* súbito: ocurre de manera abrupta.
- *Drift* gradual: se produce lentamente a lo largo del tiempo.
- *Drift incremental*: sucede progresivamente, con una transición suave entre conceptos.
- Reaparición de un concepto: un concepto antiguo vuelve a aparecer tras un periodo de ausencia.

“Si nos fijamos en los diferentes métodos y algoritmos que se usan para detectar el *drift*, los englobamos en tres grandes grupos” (Lu, J., et al. 2020):

- El primer gran grupo se basa en el *Error Rate-Based Drift Detection*. Estos algoritmos detectan cambios en función de las tasas de error observadas en los modelos de aprendizaje. Cuando la tasa de error de un clasificador cambia de manera significativa, se dispara una alarma de *drift*. Un ejemplo muy conocido es el *Drift Detection Method* (DDM), que utiliza una ventana temporal para rastrear la tasa de error en línea y generar alertas cuando detecta un aumento en dicha tasa. Otros algoritmos similares, como el *Early Drift Detection Method* (EDDM) o el *ADaptive WINdowing* (ADWIN), también se basan en el seguimiento de la tasa de error, con modificaciones para mejorar la sensibilidad o reducir los falsos positivos. Es interesante ver como estos métodos son sencillos de implementar donde hay un buen indicador del *drift*. Aunque dependen en gran medida de la tasa de error, lo que puede retrasar la detección si el cambio de concepto no afecta inmediatamente la tasa de error.

- El segundo gran grupo se basa en *Data Distribution-Based Drift Detection*. Este enfoque se enfoca en analizar cómo cambia la distribución estadística de los datos a lo largo del tiempo. En lugar de observar las tasas de error, estos algoritmos calculan la disimilitud entre la distribución de datos históricos y la de los nuevos datos. Si la diferencia es estadísticamente significativa, se declara la presencia de *drift*. Un ejemplo destacado es el uso de distancias de variación total para cuantificar la diferencia entre distribuciones. Otros métodos, como el *Information-Theoretic Approach* (ITA, por sus siglas en inglés), utilizan la divergencia de Kullback-Leibler para medir las discrepancias para cuantificar la diferencia de la densidad θ_{ITA} y así confirmar el *concept drift* cuando:

$$P(\theta_{ITA}^* \geq \theta_{ITA}) < 1 - \alpha$$

Donde:

- $P(\theta_{ITA}^* \geq \theta_{ITA})$: es la probabilidad de que el valor recalculado del estadístico de prueba θ_{ITA}^* sea mayor o igual que el valor original del estadístico θ_{ITA} .
- α : es el nivel de significancia de la prueba, que controla la sensibilidad de la detección del *drift*.

Estos métodos son efectivos ya que permiten identificar tanto el momento como la localización exacta del cambio. No obstante, cabe puntualizar que estos algoritmos requieren más recursos computacionales y más difíciles de implementar por el uso de funciones de distancia y ventanas deslizantes.

- Por último, tenemos al gran grupo de *Multiple Hypothesis Test Drift Detection*. Estos algoritmos utilizan múltiples pruebas de hipótesis de manera paralela o jerárquica para detectar *concept drift*. La innovación aquí es cómo combinan varias pruebas para mejorar la precisión en la detección. Un ejemplo de algoritmo paralelo es *Just-In-Time adaptive classifiers* (JIT, por sus siglas en inglés), que aplica múltiples pruebas de cambio en los componentes extraídos por técnicas como el Análisis de Componentes Principales (PCA, por sus siglas en inglés). También existen enfoques jerárquicos como el *Hierarchical Change-Detection Tests* (HCDTs, por sus siglas en inglés), que aplica una prueba inicial para detectar cambios y luego una capa

adicional de validación para confirmar el *drift*. Estos métodos ofrecen mayor precisión al combinar diferentes pruebas, lo que reduce falsos positivos o falsos negativos, pero puede tener un mayor costo computacional y ser más complejos, debido a la necesidad de gestionar múltiples capas de pruebas.

En los diferentes artículos y trabajos encontrados, vemos que los algoritmos más populares para la detección del *concept drift* son el DDM o ADWIN. En uno de los artículos analizados: *An online deep learning approach to handle concept drifts in predictive process monitoring* (Appice, A., et al. 2023), se ve como abordan el problema del *concept drift* en la monitorización predictiva de procesos (PPM, por sus siglas en inglés). En entornos empresariales, los procesos generan flujos de datos en constante evolución, y los modelos de predicción que asumen que los datos son estacionarios pierden precisión al no adaptarse a estos cambios. La idea principal del trabajo es utilizar un modelo de aprendizaje profundo que pueda ajustarse dinámicamente a las condiciones cambiantes en los datos de eventos empresariales. Para enfrentar el problema del *concept drift*, los autores implementan ADWIN, un detector de *concept drift* que ajusta dinámicamente el tamaño de una ventana de datos de eventos a medida que ocurren cambios. ADWIN tiene la capacidad de detectar cuándo ocurre un *drift* y ajusta la ventana de datos analizados para reflejar esos cambios de manera oportuna. La razón para usar ADWIN es que permite monitorear continuamente el error de las predicciones del modelo en tiempo real y, cuando detecta un cambio, dispara un proceso de ajuste del modelo (*fine-tuning*) basado en los datos recientes. Esto asegura que el modelo de red neuronal profunda se mantenga actualizado y adaptado a los nuevos patrones que emergen en el flujo de datos.

En otro trabajo: *Análisis y aplicación de data stream mining en mercados financieros* (Jiménez, C., 2020) nos detallan como con el uso de DDM para la detección del *concept drift* y un algoritmo de clasificación Naive Bayes, con una validación del modelo mediante la técnica *Prequential* consigue un 73% de precisión en comparación al 58.18% de precisión en el caso de no usar DDM.

2.3 Factores que más influyen en el IBEX-35

En este apartado se verán qué factores han sido los más usados para la predicción de índices bursátiles, como por ejemplo el IBEX-35.

Si se analizan qué factores son los más influyentes, la deuda pública es uno de ellos. Esta refleja el endeudamiento del país, y su nivel tiene un impacto directo en la percepción de riesgo y la estabilidad económica de España. Un aumento significativo en la deuda pública puede llevar a una disminución de la confianza en los mercados, lo que podría afectar negativamente al IBEX-35. Es importante entender que “la deuda como factor influyente, destaca su relevancia, especialmente en épocas de crisis financieras” (Cisneros, F. 2014).

“Otro factor interesante es el gasto público” (Cisneros, F. 2014). El gasto público influye en la demanda agregada de la economía, ya que representa una inyección de fondos en distintos sectores (infraestructura, salud, educación, etc.). Un aumento del gasto público puede estimular el crecimiento económico a corto plazo, afectando positivamente el mercado bursátil. Sin embargo, un gasto excesivo puede preocupar a los inversores si no es sostenible.

El Producto Interno Bruto (PIB) es uno de los indicadores económicos más importantes, ya que mide el crecimiento y la salud de la economía. Un crecimiento sostenido del PIB indica una economía en expansión, lo que generalmente es favorable para las empresas del IBEX-35 y, por tanto, para su cotización. “El PIB es de suma importancia tenerlo en cuenta en el modelo Fama-French aplicado a España” (Medarde 2014).

La tasa de desempleo también es importante, ya que “es un reflejo de las condiciones del mercado laboral y la economía en general, por lo que puede ser interesante para nuestro trabajo” (Tapia, M., 2018). Altas tasas de desempleo suelen indicar una economía débil, lo que podría reducir el consumo y afectar los ingresos corporativos, generando una posible caída en el IBEX-35.

“Otro de los factores más importantes son los tipos de interés del Banco Central Europeo (BCE)” (Gómez, M., 2024). Estos son fundamentales para el costo de financiamiento de las empresas y para las inversiones en activos financieros. Bajos tipos de interés favorecen la

inversión en bolsa, ya que los bonos y otros instrumentos de renta fija ofrecen menor rentabilidad. Por el contrario, subidas en los tipos de interés tienden a desincentivar la inversión en acciones.

El Índice de Precios al Consumo (IPC) mide la inflación, y una inflación alta puede erosionar el poder adquisitivo de los consumidores y aumentar los costos operativos de las empresas. “Si la inflación se descontrola, es probable que el BCE aumente los tipos de interés, lo que también afectaría negativamente al IBEX-35” (Rúa-Figueroa, M., 2021).

“La prima de riesgo es otro factor que influye en el IBEX-35” (Cisneros, F. 2014). La prima de riesgo mide la diferencia entre los bonos españoles y los bonos alemanes a 3 meses, y refleja el riesgo percibido de invertir en España. Un aumento en la prima de riesgo puede indicar inestabilidad económica o política, lo que afecta negativamente al IBEX-35.

“El tipo de cambio EUR/USD afecta a las empresas que exportan e importan, ya que determina la competitividad de los productos españoles en el extranjero” (Cava, A., 2015). Un euro fuerte puede perjudicar a las exportadoras, mientras que un dólar fuerte puede aumentar los costos de las importaciones.

Por último, las letras del tesoro a 3 meses también pueden influir en el IBEX-35 porque “reflejan las expectativas sobre las tasas de interés a corto plazo, lo que afecta el comportamiento de los inversores” (Lanseros, M., 2018).

2.4 Conclusiones

Tal como se ha visto en los apartados anteriores, el uso de algoritmos adaptativos y el concepto de *concept drift* en el *trading* resalta por su capacidad para manejar grandes volúmenes de datos y adaptarse a condiciones cambiantes del mercado, lo que es crucial dada la alta volatilidad en finanzas. Se han visto diferentes aplicaciones como el aprendizaje por refuerzo (RL) como un método eficaz para la toma de decisiones en tiempo real, permitiendo a los agentes ajustar sus estrategias en función de resultados anteriores y condiciones actuales. Y también el uso de algoritmos como LSTM, XGBoost o ARIMA para la predicción del cierre del IBEX-35.

Además, se ha visto cómo el *concept drift*, o el cambio en la relación entre las variables del modelo, puede impactar la precisión de las predicciones. Para abordar este desafío, se han presentado diversas metodologías de detección del *concept drift* incluyendo métodos basados en tasas de error y en la distribución de datos.

Por último, se han analizado que factores pueden tener una influencia en el IBEX-35 y que recogemos en el siguiente listado:

- Deuda pública de España
- Gasto público
- PIB de España
- Tasa de desempleo
- Tipos del BCE
- IPC
- Prima de riesgo
- EUR/USD
- Letras del tesoro a 3 meses

3. Materiales y métodos

En este apartado se analizarán los aspectos más relevantes del trabajo, la metodología que se ha seguido, junto con la descripción de los productos obtenidos. Para ello, se aprovecharán los tres grandes apartados en los que se estructura nuestro trabajo: Preprocesamiento, Análisis Exploratorio de los Datos (EDA, por sus siglas en inglés) y Aprendizaje en línea.

3.1. Preprocesamiento

El preprocesamiento constituye una de las principales etapas clave en el análisis de datos. Su objetivo principal es garantizar la calidad y la consistencia de la información utilizada en los análisis posteriores. En nuestro caso, el primer paso que se ha realizado es la carga de los datos.

La mayoría de los datos han sido extraídos de Datos Macro, Investing y Euribor Rates donde se han copiado los datos y se han guardado en un Excel para su posterior procesado. En

otros casos se ha usado la librería *Yfinance* para descargarlos directamente a nuestro Jupiter Notebook. Una vez cargado los datos se ha hecho la primera comprobación para entender las estructuras y contenidos de los datos. Seguidamente, se ha hecho una evaluación inicial para identificar posibles inconsistencias, como valores faltantes, duplicados o errores en los tipos de datos. Este paso ha permitido comprender el estado inicial de los datos y definir las transformaciones necesarias para garantizar su integridad.

Una vez se ha hecho las primeras comprobaciones hemos pasado a estandarizar y transformar las variables para adoptar un formato uniforme. El campo que ha sido más procesado ha sido el campo Fecha. Este tenía un formato de fecha de tipo texto diferente en cada una de las fuentes. Por lo tanto, se ha procedido a transformarlo en un único formato “YYYY-MM-DD”.

Un detalle importante a destacar es la frecuencia temporal de las distintas series. Si bien el IBEX-35 tiene una frecuencia de actualización diaria, los otros factores exógenos tienen una frecuencia trimestral, mensual o diaria. Para abordar este problema, se ha realizado un *forward fill* para imputar los valores faltantes propagando hacia adelante el último valor no nulo observado. Se ha optado realizar esta técnica porque se entiende que los valores de las series temporales son fijos en el tiempo, como por ejemplo el IPC. Una alternativa a *forward fill* podría ser *backward fill* donde los valores faltantes se rellenan propagando hacia atrás el próximo valor no nulo. También se podría hacer una interpolación lineal o no lineal entre los valores conocidos más cercanos. Pero en nuestro caso, se entiende que los valores trimestrales o mensuales permanecen válidos hasta la llegada de nuevas observaciones. Esta técnica asegura consistencia sin introducir valores artificiales o basados en suposiciones adicionales, respetando la naturaleza de los datos originales. Cómo a modo de resumen, dejamos los aspectos más relevantes de la etapa de preprocesado en la tabla siguiente:

FACTOR	DESCRIPCIÓN	FECHA INICIO	FECHA FINAL	FRECUENCIA	FUENTE	DÍAS TOTALES	DÍAS TOTALES POST-PROCESADO
ibex_close	Cierre diario del índice bursátil Ibex 35.	1994/01/03	2024/08/30	Diaria	yfinance	7768	7768
ibex_volume	Volumen de negociación diario del Ibex 35.	1994/01/03	2024/08/30	Diaria	yfinance	7768	7768
deuda_perc_pib	Deuda pública como porcentaje del PIB.	1995/01/02	2024/08/30	Mensual	Datos Macro	356	7518
gasto_perc_PIB	Gasto público como porcentaje del PIB.	1994/01/03	2023/12/31	Anual	Datos Macro	30	7768
pib_trim_per_capita	PIB trimestral per cápita.	1994/01/03	2024/08/30	Diaria	Datos Macro	122	7768
tasa_desempleo	Porcentaje de población activa desempleada.	1994/01/03	2024/08/30	Mensual	Datos Macro	369	7768
tie	Tipo de interés efectivo de referencia.	1999/01/04	2024/08/30	-	Datos Macro	62	6523
ipc	Índice de Precios al Consumo (inflación).	1994/01/03	2024/08/30	Mensual	Inflation.eu	369	7768
prima	Prima de riesgo española frente a Alemania.	1994/01/03	2024/08/30	Diaria	Investing	8011	7768
eurusd_close	Cierre del tipo de cambio euro-dólar.	2003/12/01	2024/08/30	Diaria	yfinance	5386	5386
tim	Tipo de interés medio de las letras del tesoro a 3 meses.	2010/01/03	2024/08/30	Mensual	Datos Macro	177	3745

Tabla 2: Tabla resumen de la etapa de preprocesado

3.2 Análisis Exploratorio de los Datos

En este apartado se analizará la metodología más relevante del Análisis Exploratorio de los Datos (EDA, por sus siglas en inglés) y se profundizará en los conceptos clave del trabajo. Lo primero que hay que tener en cuenta es la naturaleza de los datos. El componente temporal es uno de los aspectos más relevantes a abordar en este estudio, por lo que es necesario profundizar en el concepto de serie temporal.

3.2.1 Las series temporales

Como ya se ha mencionado en anteriores apartados, una serie temporal es un conjunto de datos ordenados cronológicamente, donde cada observación está vinculada a un momento específico en el tiempo. Analizar estas series permite comprender la evolución de una

variable a lo largo del tiempo, proporcionando información valiosa sobre su comportamiento histórico y tendencias futuras.

La descomposición de una serie temporal se puede expresar como:

$$X(t) = T(t) + S(t) + C(t) + E(t)$$

Donde:

- $T(t)$: Representa la tendencia, es decir, el patrón general de crecimiento o decrecimiento a largo plazo en la serie temporal.
- $S(t)$: Es la estacionalidad, que incluye los patrones regulares y repetitivos que se producen en intervalos de tiempo constantes, como ciclos anuales, trimestrales, mensuales o incluso diarios.
- $C(t)$: Corresponde a la componente cíclica, que describe las fluctuaciones irregulares que ocurren en periodos más largos que la estacionalidad, a menudo relacionadas con ciclos económicos u otros factores externos.
- $E(t)$: Es el error o residuo, que engloba la variación aleatoria o no explicada por los otros componentes. Esta componente incluye comportamientos impredecibles que, si son persistentes o sistemáticos, pueden reducir la precisión de las predicciones basadas en el modelo.

Estos componentes se han analizado junto otras pruebas estadísticas a lo largo del trabajo. No obstante, lo primero que se ha realizado ha sido una selección de las variables más relevantes, para así poder descartar aquellas que no aportan información significativa. A continuación, empezaremos con el apartado de selección de variables y explicaremos los métodos utilizados.

3.2.2 Selección de variables

En este apartado se detallarán los procesos realizados para determinar qué factores son los más relevantes para poder usarlos en nuestro algoritmo predictivo.

RFR

El modelo RandomForestRegressor es un algoritmo de aprendizaje supervisado que está construido en árboles de decisión. De esta forma, el modelo promedia las predicciones de múltiples árboles individuales y mide cuantas veces una variable es seleccionada para dividir los nodos en todos los árboles de decisión. Además, se calcula automáticamente una métrica de importancia, en este caso MSE para cada variable. La librería que se ha usado para el RFR es Sklearn.ensemble.RandomForestRegressor (Sklearn, 2024)

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N f_i(X)$$

Donde:

- \hat{y} : Es la predicción final de la variable objetivo.
- N : Es el número de árboles en el conjunto
- $f_i(X)$: Es la predicción realizada por el árbol para las características X .

RFE

El *Recursive Feature Elimination* (RFE) es otra técnica de selección de variables el cual itera por los diferentes modelos que va creando, cada uno más simple y eficiente, seleccionando las variables más importantes. En este caso RFE usa el modelo RFR y evalúa su precisión. Al igual que RFR, se ha usado RFE de la librería Sklearn.feature_selection.RFE (Sklearn, 2024).

PCA

El Análisis de Componentes Principales (PCA, por sus siglas en inglés) es una técnica comúnmente utilizada para la reducción de la dimensionalidad de un conjunto de datos grande. En este caso, PCA puede servir para ver qué variables tienen una contribución mayor en los diferentes componentes. Es decir, cuanta información explica esa variable en cada uno de los componentes. Así pues, para trabajar con PCA, lo primero que hay que hacer es estandarizar nuestra matriz de características X que será proyectada sobre los componentes principales W , obteniendo así las nuevas coordenadas del conjunto de datos:

$$Z = X * W$$

Donde:

- X : Es la matriz de datos estandarizados
- W : Es la matriz de vectores propios
- Z : Es la matriz transformada que contiene los componentes principales

Una vez se ha obtenido la matriz resultante, se pueden observar las cargas de las variables originales en los componentes $j = w_{ij}$. Esta contribución se interpreta como la magnitud de carga en el componente. Cuanto mayor la carga, mayor será la contribución. PCA se ha usado de la librería `Sklearn.decomposition.PCA` (Sklearn, 2024).

Correlación cruzada

Por último, se ha realizado una correlación de Pearson global y una correlación cruzada para ver la relación entre la variable dependiente 'ibex_close' y los demás factores exógenos. En este caso, el propósito es identificar cómo se afectan mutuamente las series en diferentes *lags*. Para usar la correlación cruzada se ha usado la librería `Statsmodels.tsa.stattools.ccf`, (Statsmodels, 2023).

El resultado que nos proporciona esta librería son unos correlogramas donde el eje X representan los *lags*. Es decir, indican el desfase temporal entre las series. Mientras que el eje Y muestra los coeficientes de correlación cruzada $PXY(k)$ que pueden tomar valores entre -1 y 1. Así pues, en la gráfica se pueden ver picos positivos, que significan que hay *lags* en que las dos series aumentan o disminuyen juntas; picos negativos, que indican que hay *lags* en los que una serie aumenta mientras la otra disminuye; y por último, si vemos que la línea va muy junta del valor 0 del eje Y significa que no hay una correlación muy fuerte en ese *lag*.

Una vez se ha realizado la selección de variables a partir de diferentes métodos, se ha determinado que las variables más relevantes para seguir en nuestro análisis son:

- El cierre del IBEX-35 (Variable dependiente)
- Deuda pública (Variable exógena)

- PIB trimestral por cápita (Variable exógena)
- Prima de riesgo (Variable exógena)
- Tasa de desempleo (Variable exógena)

A continuación, se pasará a describir los análisis realizados para así poder entender mejor las series temporales.

3.2.3 Análisis de las series temporales

Lo primero que se ha hecho es observar la distribución temporal de los factores para así poder relacionar la evolución de las series con el contexto histórico mundial. Una vez analizada la distribución se ha procedido a estudiar la variabilidad de cada serie.

Variabilidad

Para analizar la variabilidad se ha calculado el coeficiente de variación a partir de la media y la desviación estándar. “El CV es una medida que nos dice cómo de agrupado es un conjunto de datos” (Sujit, S., 2015).

$$CV = \left(\frac{\sigma}{\mu} \right) * 100$$

Donde:

- σ : Mide la dispersión de los datos respecto la media.
- μ : Es el valor medio de la serie.

Un valor de CV más elevado nos dirá que la serie tiene bastante variabilidad. En nuestro caso, cómo se está trabajando con factores económicos, la volatilidad es muy presente, por lo que los resultados pueden ser bastante altos.

Una vez se ha analizado la variabilidad se ha observado la tendencia.

Tendencia

La tendencia no es nada más que la dirección general y el patrón de crecimiento o disminución de los valores a lo largo del tiempo y que se puede entender como:

$$\text{tendencia} = \text{currentFactor}_{t-1} + \text{currentFactor}_t$$

donde:

- $\text{currentFactor}_{t-1}$: representa el valor del factor al instante de tiempo t-1
- currentFactor_t : representa el valor del factor al instante de tiempo t.

Así pues, la tendencia nos permite ver la evolución general de los datos. En caso de que la tendencia sea creciente, significará que los valores medios están aumentando a lo largo del tiempo. Y en caso contrario si la tendencia es a la baja. En cambio, si la serie presenta una tendencia horizontal, querrá decir que los valores medios se mantienen constantes en el tiempo. En este trabajo se ha analizado la tendencia y se ha establecido un nivel de significancia del 0.05 para aceptar la hipótesis nula en caso de que el resultado sea menor a este valor de p . Es decir, si el valor de $p < 0.05$ significará que hay suficiente confianza para concretar que existe tendencia en la serie. Para el cálculo de la tendencia se ha usado la librería `Statsmodels.regression.linear_model.OLS`, (Statsmodels, 2023).

Después de analizar la tendencia se ha comprobado si las series son aditivas o multiplicativas.

Serie aditiva o multiplicativa

La interpretación de los componentes de la descomposición se verá influenciada por la naturaleza de la serie.

En el caso de una serie aditiva, se entiende que la tendencia, estacionalidad y residuales se juntan de forma aditiva para formar la serie total. Es decir, que los efectos de estos tres componentes se agregan de forma lineal, y el cambio de un componente no afecta al resto.

Si, en cambio, nos encontramos una serie multiplicativa, significará que los componentes se juntan de forma multiplicativa y el cambio de uno puede afectar a la magnitud del otro.

“Para poder saber si el modelo es aditivo o multiplicativo se puede hacer la comparación entre los coeficientes de variación de las series diferencia y el cociente” (Aragon, F., 2017).

Para ello realizaremos lo siguiente:

$$\text{serie_diferenciada} = y_t - y_{t-1}$$

$$\text{serie_cociente} = \frac{y_t}{y_{t-1}}$$

$$\text{CVDt} = \frac{\text{serie_diferenciada}_\sigma}{\text{serie_diferenciada}_\mu} * 100$$

$$\text{CVCt} = \frac{\text{serie_cociente}_\sigma}{\text{serie_cociente}_\mu} * 100$$

Si observamos que CVC es más pequeño que CVD quiere decir que el modelo es multiplicativo. Si, por el contrario, CVC es mayor que CDV, es que el modelo es aditivo.

Una vez se ha analizado la naturaleza aditiva de la serie, se ha pasado a estudiar si las series presentan patrones estacionales.

Estacionalidad

La estacionalidad es un patrón o ciclo que se va repitiendo a intervalos regulares y puede tener una frecuencia estacional durante un año, o en días concretos como los fines de semana. Es decir, la variabilidad que se puede dar en un rango de fechas puede ser anual, mensual, semanal o diaria. Para analizar la estacionalidad de las distintas series se ha usado la librería `Statsmodels.tsa.seasonal.seasonal_decompose`, (Statsmodels, 2023).

Los resultados que te da esta librería se estructuran en:

- Valores originales de la serie
- Tendencia
- Componente estacional
- Residuos: Es el resultado después de eliminar la tendencia y la estacionalidad de los valores originales.

Para complementar los resultados de la descomposición estacional, se puede calcular el Índice de Variancia Estacional (IVE). Este índice es una medida que se usa para cuantificar la magnitud de la variabilidad estacional en una serie temporal.

$$no_tendencia = \frac{currentFactor_t}{\frac{1}{2} * (currentFactor_{t-1} + currentFactor_t)}$$

$$IVE = \frac{\sum_t no_tendencia_t}{N_m}$$

Donde:

- $currentFactor_t$ representa el factor estacional actual.
- N_m : Es el número de muestras en el mes m .

En el caso que los resultados del IVE sean mayores a 1, podremos entender que hay un componente estacional fuerte en el mes específico. Si el valor está por debajo a 1 querrá decir que la variabilidad estacional disminuye. Por último, si se observa un IVE igual a 1, podremos deducir que el componente estacional no contribuye a la variabilidad de la serie.

A continuación, se ha observado la relación serial de las series a partir de los resultados de la ACF y la PACF.

Autocorrelación ACF y PACF

La correlación serial de una serie nos permite ver si hay relación entre las distintas observaciones de la propia serie a lo largo del tiempo. Dependiendo de esta correlación, podremos ver si los valores pasados tienen algún tipo de influencia en las observaciones del futuro. En este caso, se ha analizado la autocorrelación y la autocorrelación parcial con la librería de *statsmodels* con las funciones *plot_acf* y *plot_pacf*, (Statsmodels, 2023).

ACF

La función de autocorrelación mide la correlación entre el momento t con varias observaciones del pasado $t-1$, $t-2$... $t-n$. Normalmente, cuanto más lejos en el tiempo, menos significancia habrá en los *lags*.

“Los valores pueden ir de -1 a 1. Un valor próximo a 1 indica una correlación fuerte entre intervalos, y, por lo tanto, los valores del día en cuestión suben siguiendo la tendencia del día

anterior. Por el contrario, si el valor es negativo, la correlación es a la inversa. Es decir, los valores de hoy suben cuando los de ayer iban a la baja.” (Villalba, R., 2020).

Los resultados de ACF nos pueden ayudar a identificar el valor de la parte autoregressiva p de los modelos ARIMA o SARIMA.

PACF

En el caso de la autocorrelación parcial, los resultados son los mismos que ACF, pero con la diferencia de que en este caso no se tienen en cuenta los intervalos intermedios. Es decir, $corr(y_t y_{t-2})$ no tendría en cuenta la influencia de y_{t-1} . Los resultados de PACF nos ayudan a identificar la media móvil de los modelos ARIMA y SARIMA.

Una vez se ha analizado la correlación serial de las series, se ha procedido a analizar la estacionariedad.

Estacionariedad

La estacionariedad en una serie significa que las propiedades estadísticas como la media, la varianza, y la autocorrelación se mantienen constantes a lo largo del tiempo. Si estas propiedades no muestran constancia en el tiempo, la serie se considera no estacionaria. Por el contrario, si estas propiedades son estables, concluiremos que la serie es estacionaria.

A continuación, mostramos ejemplos de series estacionarias y no estacionarias.




Figura 1: Ejemplo de serie no estacionaria. Realizado en R.

Una serie no estacionaria puede mostrar una tendencia, ya sea positiva o negativa, lo que provoca que la media no sea constante en el tiempo. Además, en muchos casos, la varianza también puede cambiar, afectando la estabilidad de la serie.




Figura 2: Ejemplo de serie estacionaria. Realizado en R.

En una serie estacionaria, la media y la varianza permanecen estables en el tiempo, y no hay evidencia de una tendencia creciente o decreciente. Además, las correlaciones entre observaciones dependen solo de la distancia temporal (*lag*) entre ellas, no del tiempo absoluto.

Para poder analizar si una serie es estacionaria se ha usado la prueba de Dickey-Fuller (Numxl, 2024) con la librería *statsmodels* y la función *adfuller()*, (Statsmodels, 2023):

$$\Delta y_t = \alpha + p \cdot y_{t-1} + \epsilon_t$$

Donde:

- Δy_t : es la diferencia de la serie en el tiempo $t(y_t - y_{t-1})$
- α : es el término constante (para incluir una media)
- $p \cdot y_{t-1}$: evalúa la raíz unitaria. Si $p = 0$, hay raíz unitaria y la serie no es estacionaria
- ϵ_t : es el término del error aleatorio

Seguidamente, se ha analizado la heterocedasticidad de las distintas series.

Heterocedasticidad

La presencia de heterocedasticidad en las series temporales puede perjudicar la capacidad de predicción de los modelos, ya que implica que la variabilidad de los errores no es constante a lo largo del tiempo. Esto puede llevar a estimaciones ineficientes de los parámetros y a predicciones menos precisas. Por esta razón, se ha analizado si las series presentan heterocedasticidad.

Es importante entender que la heterocedasticidad significa que la variabilidad de los errores (o residuos) no es constante. En otras palabras, la dispersión de los valores de la serie puede crecer o decrecer en diferentes partes del espacio temporal, lo que indica que la varianza depende de la posición en la serie. Esto contrasta con la homocedasticidad, en la que la variabilidad se mantiene estable.

En el caso de una serie heterocedástica, la varianza inestable provoca que en ciertas secciones de la serie los errores sean mayores, lo que podría influir negativamente en el ajuste del modelo. Para detectar la heterocedasticidad en las series, se han utilizado las pruebas de Breusch-Pagan y de White, implementadas con la librería statsmodels a través de las funciones `het_breushpagan` y `het_white`, (Statsmodels, 2023). A continuación, se presenta un ejemplo de serie heterocedástica.




Figura 3: Ejemplo de serie heterocedástica. Realizado en R.

Después de analizar la heterocedasticidad de las series, se han analizado las posibles anomalías que pueden presentarse en los diferentes factores. Para este caso se ha usado la librería IsolationForest, una técnica basada en el aislamiento de observaciones. Esto nos puede ayudar a detectar posibles valores atípicos.

3.3 Aprendizaje incremental

Este trabajo gira en torno al uso de algoritmos que se puedan usar en el aprendizaje en línea (*Online learning* en inglés). El aprendizaje en línea también es conocido como aprendizaje incremental. Es una metodología dentro del aprendizaje automático que se centra en procesar y aprender de los datos en tiempo real, uno por uno. Esto lo diferencia de otros métodos que usan grandes lotes de datos preexistentes. De hecho, en el aprendizaje en línea se habla de “los flujos de datos (*Data streams* en inglés) como una secuencia de elementos individuales que representan observaciones o muestras.” (River, 2023). Estos flujos de datos pueden tener una estructura fija, donde todas las muestras contienen las mismas características; o una estructura dinámica, donde las características aparecen y desaparecen con el tiempo dependiendo del caso de uso. Estos flujos también pueden ser reactivo o proactivos. Es decir, los datos pueden llegar de forma externa sin que se pueda tener el control de su frecuencia u orden, como, por ejemplo, las visitas a una página web y por lo tanto se le considera reactivo; o el usuario tiene el control del flujo de datos, como por ejemplo la extracción y lectura de datos diaria del precio de cierre del IBEX-35.

Como ya hemos dicho, esta metodología se enfoca en el procesamiento en línea (*Online processing* en inglés). Este enfoque permite a los modelos a procesar los datos de manera incremental, observando una muestra a la vez, a diferencia del aprendizaje tradicional que aprendes por grandes bloques de datos en una vez. Por lo tanto, estos modelos en línea son dinámicos y con estados. Es decir, les permite adaptarse a nuevos cambios en los datos sin necesidad de revisar los datos pasados. Pero no todo queda resuelto con el procesamiento en línea. Puede ocurrir que haya un cambio en los datos muy abrupto y que incluso los modelos en línea se vean desfasados. En este caso, se ha desarrollado la manera de captar estos cambios y que se conocen como *concept drift*. A continuación, se hablará de los métodos usados para monitorizar el *concept drift*, los indicadores estadísticos usados para ver el rendimiento de los modelos y los propios modelos usados.

3.3.1 *Concept drift*

En el apartado del Estado del arte ya se ha profundizado en el *concept drift* y ya sabemos que este ocurre cuando las relaciones estadísticas entre las características de entrada y las etiquetas objetivo cambian con el tiempo, produciendo un problema en el modelo. Este fenómeno es común en sistemas en producción donde los datos evolucionan y presentan una alta volatilidad como es el caso de las finanzas.

La monitorización del *concept drift* puede tener mucho sentido cuando se hace el aprendizaje por lotes. Estos modelos se entrenan en un conjunto de datos histórico fijo, con lo que el modelo puede quedar atrapado en patrones históricos y pierde precisión cuando los nuevos datos presentan un patrón completamente diferente. En el caso de que esto ocurra, será necesario recopilar nuevos datos y reentrenar el modelo completo, lo que puede ser costoso en tiempo y recursos. En el caso de los modelos en línea, el *concept drift* no presenta tanto un problema, debido a que estos modelos se entrenan y actualizan continuamente con cada nueva muestra de datos. En nuestro trabajo, los modelos se entrenan cada día, con los nuevos datos que se han registrado en el IBEX-35. Esta capacidad de aprendizaje incremental les permite adaptarse más rápidamente al *concept drift*, ya que pueden integrar información más reciente en el modelo. Pero, esto no significa que el problema esté completamente resuelto. Depende del *concept drift*, la adaptación puede ser lenta. Por ejemplo, si tenemos un *drift* súbito, pueden surgir problemas como la pérdida de patrones importantes del pasado. Es por ello, que monitorizar el *concept drift* en nuestro aprendizaje

en línea puede beneficiar todavía más las predicciones. En este caso, se han usado dos métodos para detectar el *concept drift*: ADWIN y KSWIN.

ADWIN

Adaptive Windowing (ADWIN, por sus siglas en inglés) es un algoritmo diseñado para detectar el *concept drift* en flujos de datos de manera eficiente. El objetivo principal es mantener el modelo actualizado eliminando automáticamente datos antiguos que ya no representan correctamente la distribución actual. “ADWIN mantiene eficientemente una ventana de longitud variable de elementos recientes, de modo que se sostiene que no ha habido cambios en la distribución de datos. Esta ventana se divide en dos subventanas que se utilizan para determinar si se ha producido un cambio.” (River, 2023). Este cambio se basa en test de hipótesis estadísticos donde primero se calcula la diferencia entre las medias de las dos subventanas y luego se evalúa si esta diferencia excede un umbral estadísticamente significativo, considerando el error estándar. En caso de que se interprete el *drift* los datos más antiguos se eliminan para así poder dejar la parte más relevante del flujo.

En nuestro caso, se ha usado ADWIN de la librería River y se ha configurado de la siguiente manera:

```
ADWIN(delta=0.002, clock=1, max_buckets=100, min_window_length=10,
grace_period=10)
```

Código 1: Configuración de ADWIN.

- **delta = 0.002:** Es el nivel de significancia estadística para la detección de cambios. Los valores más pequeños hacen que ADWIN sea más estricto, como es en nuestro caso.
- **clock = 1:** Controla la frecuencia con la que el algoritmo revisa los datos para detectar cambios. En este caso se ha puesto 1 para así poder realizar la revisión con cada nuevo dato y así ser más precisos en la detección del *drift*.
- **max_buckets = 100:** Establece el número máximo de *buckets* por tamaño que ADWIN puede mantener para fusionarlos en la ventana deslizante. En este caso, se

ha puesto un valor alto para así priorizar la precisión en vez del costo de memoria y computacional.

- **min_window_length = 10:** Define el tamaño mínimo de las subventanas que el algoritmo evalúa para detectar *drifts*.
- **grace_period = 10:** Establece cuántos datos deben llegar antes de que ADWIN comience a realizar la detección de *drift*. Este valor es el que hay por defecto en el algoritmo y favorece un equilibrio entre rapidez para empezar a detectar y minimizar errores iniciales en datos inestables.

KSWIN

El método Kolmogorov-Smirnov Windowing (KSWIN, por sus siglas en inglés) utiliza el test de Kolmogorov-Smirnov para detectar cambios conceptuales en flujos de datos unidimensionales. KSWIN detecta el *concept drift* “si la diferencia en las distribuciones de datos empíricos entre las ventanas es demasiado grande, ya que provienen de la misma distribución.” (River, 2023). Para usar este método se ha usado KSWIN de la librería River. A continuación, se presenta la configuración de los parámetros que se ha usado:

```
KSWIN(alpha=0.002, seed=42, window_size=300, stat_size=50)
```

Código 2: Configuración de KSWIN.

- **alpha = 0.002:** Define el nivel de significancia del test KS, controlando la probabilidad de rechazar la hipótesis nula incorrectamente. Es decir, trata de detectar un *drift* cuando no lo hay. Un valor bajo, como el que se ha puesto hace que el test sea más estricto.
- **seed = 42:** Controla la semilla para la generación de números aleatorios.
- **window_size = 300:** Determina el tamaño de la ventana deslizante que mantiene las muestras más recientes del flujo de datos. El valor que se ha puesto permite crear una ventana grande para así captar cambios más graduales, pero puede retrasar la detección de *drifts* súbitos.
- **stat_size = 50:** Define el tamaño de la subventana estadística que representa la última distribución conocida. En este caso, se ha preferido proporcionar una ventana más grande para obtener una estimación más precisa de la distribución.

A continuación, se detallarán los indicadores estadísticos usados para la monitorización del rendimiento de los modelos y más adelante veremos los modelos usados.

3.3.2 Indicadores estadísticos de los modelos

En este apartado se presentarán los indicadores que se han usado para ver la calidad de las predicciones de los diferentes algoritmos usados. En este caso se ha usado la librería *river* y su paquete *metrics* (River, 2023), para poder calcular las métricas que presentamos a continuación.

MAE

El Error Absoluto Medio (MAE, por sus siglas en inglés) mide el promedio de las diferencias absolutas entre los valores reales y los predichos.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \bar{y}|$$

Donde:

- n : Es el número de observaciones.
- y_i : Son los valores reales de la variable dependiente
- \bar{y} : Son los valores predichos por el modelo
- $|y_i - \bar{y}|$: Error absoluto entre cada valor real y su predicción

MSE

El Error Cuadrático Medio (MSE, por sus siglas en inglés) es una métrica que se usa para medir la calidad de un modelo predictivo. Nos dice el promedio de los errores al cuadrado entre los valores reales y los predichos. Su fórmula sería la siguiente:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

Donde:

- n : Es el número de observaciones.

- y_i Son los valores reales de la variable dependiente
- \hat{y} : Son los valores predichos por el modelo

RMSE

El Error Cuadrático Medio elevado al cuadrado nos da el mismo resultado que el MSE pero en la misma escala que la variable original.

$$RMSE = \sqrt{MSE}$$

MAPE

El Error Porcentual Absoluto Medio (MAPE, por sus siglas en inglés) es una métrica que mide el promedio de los errores absolutos como un porcentaje de los valores reales.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y - \hat{y}}{y} \right| \times 100$$

- y_i Son los valores reales de la variable dependiente
- \hat{y} : Son los valores predichos por el modelo
- n : Es el número de observaciones.
- $\left| \frac{y - \hat{y}}{y} \right|$: Error relativo absoluto de cada observación, expresado como un porcentaje.

R2

El coeficiente de determinación es una métrica que mide qué proporción de la variación total en una variable dependiente es explicada por el modelo en relación con la variación total.

$$R^2 = 1 - \left(\frac{SSR}{SST} \right)$$

Donde:

- SSR : Es la suma de los cuadrados de los residuos.
- SST : Es la suma total de los cuadrados.

3.3.3 Modelos

Una vez se ha hecho el análisis de las series y se han identificado los factores que más pueden influir en la predicción del cierre del IBEX-35, se ha pasado a codificar los algoritmos para la fase de predicción. En este caso, se han usado dos algoritmos: SNARIMAX y Holt Winters.

SNARIAMAX

El algoritmo *Seasonal Non-linear AutoRegressive Integrated moving-Average with Exogenous* (SNARIMAX, por sus siglas en inglés) es un modelo generalizado usado en el análisis y la predicción de series temporales. Este algoritmo usa múltiples componentes y es adaptable al aprendizaje incremental. Es decir, es ideal para trabajar en escenarios donde los datos llegan de manera continua y se requiere tener controlado el *concept drift*. Se ha creído oportuno usar SNARIMAX de la librería River, (River, 2023), ya que la alta volatilidad del IBEX-35 permite ser capturada mediante la monitorización del *concept drift* y adaptar el algoritmo a la nueva entrada de datos.

Tal como podemos ver en el [Código 3: Función para crear un modelo SNARIMAX](#), los parámetros de SNARIMAX se han configurado de la siguiente manera:

- **P = 1 (Autoregressive order):** Se usa el valor de y_{t-1} como predictor. Esto permite capturar relaciones inmediatas entre los valores consecutivos del cierre del IBEX-35.
- **d = 1 (Differencing order):** Esto indica que los datos se diferencian una vez para garantizar que la serie sea estacionaria. En nuestro caso, ninguna serie es estacionaria, según los resultados de las pruebas de *Dickey Fuller* aumentado. Por eso, se ha configurado el orden de diferenciación a 1.
- **q = 0 (Moving Average order):** Este parámetro se usa para indicar los errores pasados que se tienen que contemplar como predictores. En nuestro caso, se asume que los errores no tienen una estructura predecible y por eso se ha puesto como 0.
- **Regressor:** Se ha usado un *regressor* para normalizar los datos y así estabilizar las varianzas y mejorar la convergencia del modelo. Y también se ha usado una regresión lineal como *regressor* base inicial con un intercepto cerca de un valor promedio esperado del IBEX-35 y así poder ayudar a estabilizar el modelo en las primeras iteraciones; un optimizador del gradiente estocástico con una tasa de

aprendizaje de 0.01, ideal para el aprendizaje incremental; y, por último, se ha usado un ajuste de la tasa de aprendizaje del intercepto a 0.3, permitiendo un ajuste más dinámico al *concept drift*.

Holt Winters

El modelo de Holt Winters es un método de suavización exponencial para la predicción de series temporales. Es ideal para series que presentan tendencias y por eso se ha usado. Igual que SNARIMAX, Holt Winters se ha estirado de la librería River, (River, 2023). Este algoritmo combina tres componentes principales:

- **Nivel:** Representa el promedio o estado base de la serie en un momento dado.
- **Tendencia:** Captura cambios persistentes en la dirección de los datos.
- **Estacionalidad:** Refleja patrones repetitivos en intervalos regulares.
- **Multiplicatividad:** Tiene en cuenta si la serie es aditiva o multiplicativa.

Se puede observar la configuración del algoritmo a partir del **Código 4: Configuración del algoritmo de Holt Winters**. Como nuestras series son multiplicativas y tienen tendencia, se han usado los siguientes valores en los diferentes parámetros del algoritmo:

- ***alpha* = 0.3:** Con *alpha* se controla el suavizado del nivel. En nuestro caso, se ha optado por responder a los cambios recientes en el nivel de manera moderada.
- ***beta* = 0.1:** *beta* permite ajustar la suavización de la tendencia. Un valor bajo permite estabilizar la tendencia.
- ***gamma* = 0.6:** *gamma* determina el peso de la estacionalidad. En el caso de valores altos se permite una adaptación rápida a cambios en patrones estacionales. Como en nuestro caso, los patrones pueden cambiar frecuentemente, se ha optado por poner un valor moderado alto para dar mayor peso a los cambios recientes en los patrones estacionales.
- ***multiplicative* = True:** El parámetro multiplicativo se refiere a que el cambio de uno puede afectar a la magnitud del otro *lag*. En nuestro caso, el cierre del IBEX-35 es multiplicativa y por eso se ha seleccionado como *True* este parámetro.

Seguidamente, veremos los resultados de los métodos que hemos estado detallando en este apartado.

4. Resultados

En este apartado de Resultados se expondrán los resultados y las conclusiones de cada uno de los métodos y pruebas que se han comentado en el apartado anterior. Se empezará por ver la selección de variables.

4.1 Selección de variables

Los resultados sobre la selección de variables más relevantes se han resumido en la [Tabla 9: Resultados de la selección de variables](#). En ella se puede observar que después de realizar RFR, RFE, PCA y la correlación de Pearson acabamos seleccionando aquellas variables que han salido que Sí en al menos tres métodos. Así pues, las variables que cumplen con este criterio son la Deuda pública, la Prima de riesgo, el Gasto público y la Tasa de desempleo.

A continuación, se mostrarán los resultados de la correlación cruzada.

4.2 Correlación cruzada

El cálculo de la correlación cruzada se ha hecho teniendo en cuenta la serie dependiente “Ibex_close” y los cuatro factores exógenos que hemos seleccionado anteriormente.

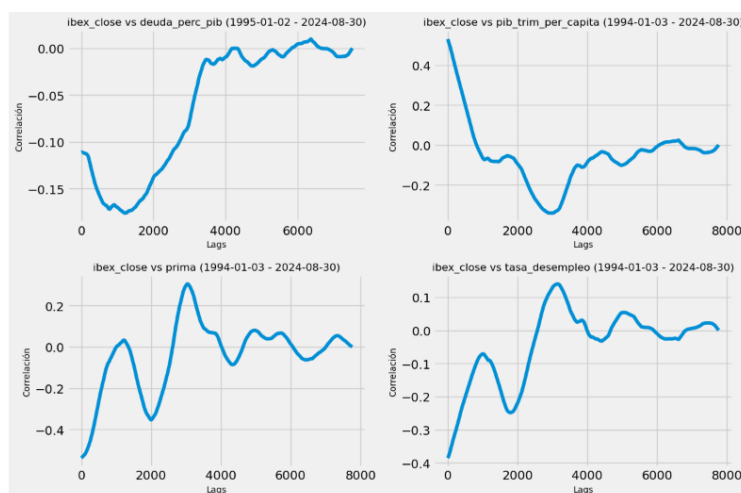


Figura 4: Resultados de la correlación cruzada.

- La deuda pública muestra una correlación negativa en los primeros 4000 *lags*, indicando que el IBEX-35 tiende a bajar cuando la deuda aumenta, pero la relación pierde relevancia a medida que aumenta el desfase temporal.
- El PIB trimestral per cápita presenta una correlación positiva al principio, pero a medida que el desfase aumenta, la relación se debilita, incluso volviéndose negativa en algunos puntos, antes de estabilizarse.
- La prima de riesgo muestra una relación compleja, con picos negativos en los primeros *lags*, sugiriendo que su impacto en el IBEX-35 es negativo a corto plazo, pero fluctuante a largo plazo.
- La tasa de desempleo sigue un patrón similar al de la prima de riesgo, con correlaciones negativas al principio y fluctuaciones que indican una relación débil o nula a largo plazo.

Seguidamente, veremos los resultados del coeficiente de variación.

4.3 Variabilidad según el coeficiente de variación

El coeficiente de variación nos permite observar la variabilidad que tenemos en nuestra serie. Los resultados de esta operación son los siguientes:

Factor	CV
ibex_close	28,3
deuda_perc_pib	36,31
pib_trim_per_capita	25,03
tasa_desempleo	106,2
prima	31,69

Tabla 3: Resultado del coeficiente de variación

Los resultados de las variables analizadas presentan niveles de variabilidad heterogéneos, reflejando la naturaleza de los fenómenos que representan. La prima de riesgo y la deuda pública destacan por su alta volatilidad, respondiendo rápidamente a cambios económicos y políticos. En contraste, el PIB per cápita y el cierre del IBEX-35 presentan variabilidad moderada, siendo más estables pero influenciados por ciclos económicos. La tasa de desempleo también refleja una sensibilidad significativa, especialmente en periodos de crisis.

Una vez se ha visto la variabilidad de los datos en cada serie se pasará a los resultados de la tendencia.

4.4 Tendencia

La tendencia es una de las medidas más importantes ya que permite ver la tendencia de las series temporales. En la tabla siguiente se muestra los resultados de tendencia para cada serie.

Factor	Tendencia	Valor p	Hay_tendencia
ibex_close	0.412	0.000	TRUE
deuda_perc_pib	0.010	0.000	TRUE
pib_trim_per_capita	0.001	0.000	TRUE
prima	-0.003	0.000	TRUE
tasa_desempleo	0.000	0.021	TRUE

Tabla 4: Resultados de la tendencia.

Los resultados muestran tendencias significativas en todas las variables analizadas. El IBEX-35 presenta un aumento consistente, reflejo de un crecimiento en el mercado bursátil, mientras que la prima de riesgo disminuye, indicando una percepción de mayor estabilidad económica. La deuda pública y el PIB per cápita tienen tendencias positivas, aunque moderadas, lo que apunta a un crecimiento sostenido pero limitado en ambos indicadores. Por otro lado, la tasa de desempleo muestra una tendencia estadísticamente significativa, pero con una variación prácticamente nula, sugiriendo una estabilidad relativa en el tiempo sin grandes cambios estructurales.

A continuación, se presentará los resultados de la naturaleza aditiva de las series.

4.5 Serie aditiva o multiplicativa

Para poder ver cómo se relacionan los componentes de estacionalidad, residuales y tendencia vemos la diferencia entre el coeficiente de variación cociente y el coeficiente de variación diferenciado. Los resultados se muestran en la siguiente tabla:

Factor	CVC	CVD	Aditiva
ibex_close	57.22	0.28	TRUE
deuda_perc_pib	45.38	0.36	TRUE
pib_trim_per_capita	24.17	0.25	TRUE
prima	-25.80	1.06	FALSE
tasa_desempleo	-45.28	0.32	FALSE

Tabla 5: Resultados de si las series son multiplicativas o aditivas

Podemos ver que el IBEX-35, la Deuda Pública y el PIB per cápita tienen una naturaleza multiplicativa, lo que implica que sus variaciones son proporcionales a sus valores absolutos. Por el contrario, la Prima de Riesgo y la Tasa de Desempleo son aditivas, mostrando cambios absolutos más relevantes que los relativos.

Seguidamente, se pasará a ver la estacionalidad de las series.

4.6 Estacionalidad

Comprobar la estacionalidad, es uno de los requisitos más importantes, ya que permite filtrar los posibles modelos que se pueden usar en la etapa de predicción. En este caso, se puede ver que no hay presencia de estacionalidad en las series. De hecho, en la **Tabla 10: Resultados del Índice de Variancia Estacional** se puede ver el resultado sobre el cálculo del Índice de Variación Estacional. Tal como se puede observar en el resultado del IVE, la mayoría de las series tienen fluctuaciones pequeñas (cercanas a 1), lo que indica que las variaciones estacionales no son muy marcadas.

A continuación, pasaremos a ver los resultados de ACF y PACF.

4.7 Autocorrelación (ACF y PACF)

En este apartado se mostrará los resultados de la función de autocorrelación y de la autocorrelación parcial.

4.7.1 Autocorrelación (ACF)

La función de autocorrelación muestra una fuerte correlación cercana a 1 en los primeros 20 *lags* y luego empieza a disminuir levemente en el caso del IBEX-35. En el caso de las demás series, la correlación se extiende por más *lags*, lo que sugiere patrones de dependencia temporal más prolongados. Para el IBEX-35, este comportamiento indica que

los valores de los primeros días están fuertemente relacionados entre sí, lo que sugiere una tendencia persistente en el corto plazo. Esto implica que los movimientos de los primeros días se reflejan fuertemente en los días siguientes. Este tipo de comportamiento es común en series financieras, donde las fluctuaciones a corto plazo suelen estar autocorrelacionadas.

Por otro lado, las otras series presentan una autocorrelación más persistente a lo largo del tiempo, lo que sugiere que tienen una dependencia temporal más duradera.

4.7.2 Autocorrelación Parcial (PACF)

En la autocorrelación parcial (PACF), los primeros dos *lags* muestran una correlación de 1, mientras que el resto de los *lags* se acercan a 0. Esto indica que, para todas las series analizadas, los primeros dos periodos tienen una fuerte correlación, pero después la correlación se desvanece rápidamente. Este patrón sugiere que las series podrían seguir un proceso de tipo AR(1) o AR(2), es decir, los valores en el tiempo actual dependen principalmente de los dos valores previos, pero no muestran dependencia significativa después de esos dos *lags*. Este comportamiento es consistente con series temporales que tienen memoria a corto plazo, en las que las observaciones recientes influyen de forma importante en las futuras, pero no más allá de esos primeros *lags*. Lo que significa también que es común en datos económicos y financieros, donde las fluctuaciones de corto plazo suelen tener un impacto más inmediato, pero una vez transcurridos unos pocos periodos, la influencia de los valores previos se vuelve mínima.

Seguidamente, se presentará los resultados de estacionariedad de las series.

4.8 Estacionariedad

“Una forma de comprobar si una serie temporal es estacionaria es realizar una prueba Dickey-Fuller aumentada” (Bobbitt, Z., 2021). En la tabla siguiente se presentan los resultados.

Factor	EstadisticP_ADF	ValorP	5%	Es_estacionaria
ibex_close	-2.46	0.13	-2.86	No
deuda_perc_pib	0.13	0.97	-2.86	No
pib_trim_per_capita	-0.59	0.87	-2.86	No
prima	-1.75	0.41	-2.86	No
tasa_desempleo	-1.36	0.60	-2.86	No

Tabla 6: Resultados de estacionariedad. prueba Dickey Fuller

Los resultados muestran que ninguna de las series es estacionaria, ya que en todos los casos el valor p es mayor que 0.05, lo que impide rechazar la hipótesis nula de no estacionariedad. El estadístico ADF en todos los casos también está por encima del umbral del 5%, lo que refuerza esta conclusión.

A continuación, se pasará a ver el resultado de heterocedasticidad.

4.9 Heterocedasticidad

La presencia de heterocedasticidad implica que la serie no es homocedástica. Es decir, la varianza de los errores no es constante a lo largo del tiempo. En la siguiente tabla se presentan los resultados de las pruebas de Pagan y White.

Factor	ValorP_Pagan	ValorP_White
ibex_close	0.0	0.0
deuda_perc_pib	0.0	0.0
pib_trim_per_capita	0.0	0.0
prima	0.0	0.0
tasa_desempleo	0.0	0.0

Tabla 7: Resultados de la heterocedasticidad. Pruebas de Pagan y White.

Las pruebas de Breusch-Pagan y White revelan que todos los factores analizados son heterocedásticos, ya que los valores de p para ambas pruebas son muy bajos (0.0), lo que permite rechazar la hipótesis nula de homocedasticidad con un alto nivel de confianza. Esto indica que la varianza de los errores en el modelo de regresión no es constante

Una vez se han presentado los resultados del análisis exploratorio de los datos, se pasará a ver los resultados de los modelos de aprendizaje incremental.

4.10 Aprendizaje incremental

En este apartado se analizarán los resultados de los siguientes modelos entrenados para hacer una valoración sobre su rendimiento y determinar qué modelo es el mejor.

En la siguiente tabla mostramos un resumen de los resultados de los modelos ordenados por el MAE.

MODELO	MAE	MSE	RMSE	MAPE	R2
SNARIMAX_no_exo_si_adwin	107.030	25745.295	160.453	1.224	0.996
SNARIMAX_no_exo_no_adwin	107.912	26654.242	163.261	1.234	0.996
SNARIMAX_w3_no_adwin	111.574	28399.252	168.521	1.279	0.996
SNARIMAX_w3_si_kswin	112.015	28344.643	168.359	1.283	0.996
SNARIMAX_w3_si_adwin	112.114	28439.134	168.639	1.285	0.996
SNARIMAX_w4_si_adwin	117.966	30608.037	174.952	1.324	0.994
Holt_Winters_no_drift	123.485	29752.873	172.490	1.411	0.995

Tabla 8: Resultados de los modelos adaptativos.

En este análisis, se muestran los resultados de varias configuraciones de modelos predictivos aplicados a un problema de series temporales, con el objetivo de predecir el valor de cierre del IBEX-35 en función de diferentes factores y métodos de monitoreo del *drift*. Las métricas clave de desempeño son el MAE (Error Absoluto Medio), el MSE (Error Cuadrático Medio), el RMSE (Raíz del Error Cuadrático Medio), el MAPE (Error Absoluto Porcentual Medio) y el R^2 (Coeficiente de Determinación). A continuación, se detallan los resultados obtenidos para cada modelo.

4.10.1 SNARIMAX_no_exo_si_adwin

Este modelo no utiliza factores exógenos, pero incorpora monitoreo de *drift* mediante ADWIN. Vemos que este modelo ha dado los mejores resultados. La adición de ADWIN mejora la capacidad del modelo para detectar y adaptarse a cambios conceptuales en los datos y permite mantener un rendimiento muy fuerte, con un R^2 de 0.996, lo que indica que el modelo explica el 99.6% de la variabilidad de los datos.

El MAE de 107.030 sugiere que, en promedio, las predicciones se desvían de los valores reales en aproximadamente 107 puntos, lo cual es relativamente alto en un contexto financiero.

El MSE y el RMSE, de 25745.295 y 160.453 respectivamente, siguen siendo altos, lo que refleja la sensibilidad del modelo a los errores más grandes y la existencia de posibles valores atípicos en los datos.

El MAPE de 1.224% indica que el modelo sigue siendo muy preciso en términos porcentuales, manteniéndose también por debajo del 2%. Esto demuestra que el modelo es efectivo a la hora de predecir las tendencias, incluso con la inclusión de ADWIN.

4.10.2 SNARIMAX_no_exo_no_adwin

Este modelo no incorpora factores exógenos ni utiliza monitoreo de *drift* (ADWIN ni KSWIN), lo que lo hace más simple y autónomo. A pesar de esta simplicidad, presenta un rendimiento notablemente fuerte con un R^2 de 0.996, lo que significa que explica el 99.6% de la variabilidad en los datos observados.

El MAE de 107.912 indica que, en promedio, las predicciones difieren de los valores reales en aproximadamente 108 puntos. Es un valor elevado, dado que estamos trabajando con datos financieros.

El MSE y el RMSE, de 26654.242 y 163.261 respectivamente, reflejan la magnitud de los errores, penalizando más los valores atípicos. En este caso, también son bastante elevados. Finalmente, el MAPE es del 1.234%, lo que significa que las predicciones son muy precisas en términos porcentuales, manteniéndose por debajo del umbral del 2%. Esto significa que, aunque las diferencias absolutas son considerables, el modelo es robusto para identificar tendencias y patrones dentro de los datos.

4.10.3 SNARIMAX_w3_no_adwin

Este modelo utiliza tres factores exógenos sin monitoreo de *drift*, lo que lo hace menos adaptable a cambios conceptuales en los datos en comparación con los modelos con ADWIN. A pesar de esta limitación, el modelo sigue teniendo un rendimiento sólido, con un R^2 de 0.996, lo que indica que es capaz de explicar el 99.6% de la variabilidad de los datos. El MAE de 111.574 muestra que las predicciones difieren en promedio por 112 puntos de los valores reales, por lo tanto, vemos que el uso de exógenas sin monitorizar el *drift* perjudica más a las predicciones del modelo.

El MSE y el RMSE, de 28399.252 y 168.521 respectivamente, siguen siendo relativamente altos, lo que refleja que el modelo tiene dificultades para ajustarse completamente a los datos y que las diferencias en los valores reales y predichos son notables.

El MAPE de 1.279% es ligeramente peor que en los modelos anteriores.

4.10.4 SNARIMAX_w3_si_kswin

Este modelo incorpora tres factores exógenos junto con monitoreo de *drift* utilizando KSWIN. Al agregar KSWIN, el modelo es capaz de adaptarse a los cambios en los datos, pero su desempeño sigue siendo comparable a otros modelos con monitoreo de *drift*. El R^2 de 0.996 sugiere que el modelo sigue siendo efectivo en la explicación de la variabilidad de los datos. El MAE de 112.015 indica que las predicciones difieren en promedio por 112 puntos de los valores reales, lo cual es similar al modelo anterior donde no monitorizamos el *concept drift*. El MSE y el RMSE, de 28344.643 y 168.359 respectivamente, son similares a los modelos anteriores, lo que refleja que la adición de KSWIN no ha reducido significativamente la magnitud de los errores.

El MAPE de 1.283% sigue siendo bastante bajo, lo que demuestra que, en términos porcentuales, las predicciones siguen siendo muy precisas.

4.10.5 SNARIMAX_w3_si_adwin

Este modelo incorpora tres factores exógenos y el monitoreo de *drift* con ADWIN. La inclusión de estos factores mejora la flexibilidad del modelo, pero la capacidad predictiva es ligeramente inferior en comparación con los modelos sin factores exógenos. El R^2 de 0.996 sigue siendo muy alto, indicando una excelente capacidad para explicar la variabilidad en los datos.

El MAE de 112.114 sugiere que las predicciones difieren en promedio por 112 puntos de los valores reales. Aunque sigue siendo alto en términos absolutos.

El MSE de 28439.134 y el RMSE de 168.639 son altos, reflejando la sensibilidad del modelo a errores más grandes y mostrando que la inclusión de factores exógenos introduce más variabilidad.

El MAPE de 1.285% indica que el modelo sigue siendo bastante preciso en términos porcentuales, manteniéndose bajo el 2% y demostrando que es efectivo para identificar las tendencias en los datos.

4.10.6 SNARIMAX_w4_si_adwin

En este modelo, se incorporan cuatro factores exógenos junto con el monitoreo de *drift* mediante ADWIN. A pesar de la incorporación de más variables para mejorar las predicciones, el rendimiento muestra un pequeño descenso en comparación con los modelos anteriores. El R^2 es de 0.994, lo que sigue siendo muy alto, pero indica que el modelo ahora explica un 99.4% de la variabilidad en los datos, ligeramente menos que los modelos sin factores exógenos.

El MAE de 117.966 refleja un incremento en el error promedio, con las predicciones desviándose en aproximadamente 118 puntos en promedio, lo cual podría considerarse algo elevado en términos financieros.

El MSE y RMSE, de 30,608.037 y 174.952 respectivamente, son más altos que en los modelos anteriores, lo que sugiere que las adiciones de factores exógenos aumentan la complejidad del modelo y pueden introducir más ruido, afectando su rendimiento general.

El MAPE de 1.324% sigue siendo inferior al 2%, lo que sugiere que, a pesar de la mayor complejidad del modelo, las predicciones siguen siendo bastante precisas en términos relativos.

4.10.7 Holt_Winters_no_drift

Este modelo utiliza el método de Holt-Winters para predicción sin monitoreo de *drift*, lo que implica que no es tan sensible a los cambios conceptuales en los datos como los modelos con ADWIN o KSWIN. El rendimiento es más modesto, con un R^2 de 0.995, lo que indica que el modelo explica el 99.5% de la variabilidad de los datos, un valor ligeramente inferior al de los modelos SNARIMAX.

El MAE de 123.485 muestra que las predicciones difieren en promedio por 123 puntos de los valores reales, lo que es un poco más alto que en los modelos SNARIMAX. Este valor es un indicativo de que el modelo tiene más dificultades para ajustarse a los datos de manera precisa.

El MSE de 29752.873 y el RMSE de 172.490 reflejan una penalización más alta por los errores más grandes, lo que sugiere que el modelo tiene dificultades para manejar ciertos valores atípicos o errores significativos.

El MAPE de 1.411% es más alto en comparación con los otros modelos, lo que indica que las predicciones en términos porcentuales son algo menos precisas, pero aún se mantienen dentro de un rango razonable.

Después de analizar los resultados de los modelos implementados, se puede ver como el modelo SNARIMAX sin variables exógenas y con la monitorización del *concept drift* ha dado los mejores resultados.

A continuación, se concluirá el trabajo con unas conclusiones.

5. Conclusiones y trabajos futuros

El modelo SNARIMAX univariado, junto con la detección del *concept drift* con ADWIN, ha destacado como la solución más robusta para la predicción del IBEX-35, logrando un R^2 de 0.996 y un MAPE del 1.224%, lo que refleja una alta precisión. El monitoreo del *drift* mediante ADWIN ha permitido mantener el rendimiento del modelo frente a cambios en la distribución de los datos. Es importante destacar también que la configuración de SNARIMAX, usando un regresor sin factores exógenos, ha permitido simplificar el modelo sin comprometer su precisión, optimizando su aplicabilidad en entornos con limitaciones de datos adicionales.

Sin embargo, el MAE de 107.030 indica que todavía existen errores significativos en promedio, especialmente en contextos de alta volatilidad, sugiriendo posibles mejoras futuras. Estos resultados, aunque alineados con las expectativas iniciales, han sido sorprendentes en cuanto a la eficacia del modelo sin factores exógenos. Una reflexión crítica que podemos hacer sobre el trabajo es que los objetivos principales de diseñar un modelo capaz de adaptarse a cambios en los datos y realizar predicciones precisas fueron alcanzados. Sin embargo, no todos los objetivos secundarios, como la incorporación de factores exógenos, fueron plenamente explorados. La simplicidad del modelo sin exógenos ha permitido una alta precisión, pero explorar estas variables podría ser clave para futuras mejoras.

La planificación inicial y la metodología diseñada fueron adecuadas, ya que permitieron una implementación eficiente de las tres etapas clave: preprocesamiento, análisis exploratorio de los datos y aprendizaje incremental. Esto asegura que el enfoque fue bien estructurado y adaptable. Por lo que respecta a los impactos ético-sociales, no se han identificado impactos negativos, ya que se han usado únicamente datos públicos, garantizando la transparencia y responsabilidad en el uso de los datos.

Por último, cabe destacar que este proyecto abre múltiples líneas de investigación futuras. En primer lugar, es interesante explorar otros factores exógenos para capturar más variabilidad en los datos y mejorar la precisión del modelo en situaciones de alta volatilidad. Además, poner en producción el modelo que ha mostrado los mejores resultados podría ser una gran oportunidad para lograr competencias prácticas esenciales en el ámbito de la ciencia de datos.

En este sentido, se propone montar un servidor en una máquina Linux donde los programas estén listos para realizar predicciones y reentrenar el modelo diariamente, después de la publicación del cierre del IBEX-35. Esto podría implementarse de manera sencilla con FastAPI, permitiendo el acceso al modelo mediante diferentes *endpoints*. Los datos diarios podrían extraerse mediante técnicas de scraping y procesarse con flujos ETL antes de ser almacenados en una base de datos, como PostgreSQL. Con esta infraestructura en funcionamiento, se podría automatizar el proceso de actualización y predicción diaria, asegurando la escalabilidad y adaptabilidad del modelo en un entorno real.

6. Glosario

- **Aprendizaje Incremental:** Técnica de aprendizaje automático en la que un modelo se actualiza continuamente a medida que recibe nuevos datos, sin necesidad de reentrenar desde cero, permitiendo adaptarse a cambios en la distribución de los datos en tiempo real.
- **Concept Drift:** Fenómeno que ocurre cuando la relación entre las variables de entrada y la variable objetivo cambia con el tiempo, afectando la precisión de los modelos predictivos.
- **ADWIN (Adaptive Windowing):** Algoritmo utilizado para la detección de *concept drift* que ajusta dinámicamente una ventana de datos para identificar cambios significativos en las distribuciones de datos.
- **KSWIN (Kolmogorov-Smirnov Windowing):** Algoritmo para la detección de *concept drift* basado en la prueba estadística de Kolmogorov-Smirnov.
- **Heterocedasticidad:** Situación en la que la varianza de los errores en un modelo de regresión no es constante, lo que puede afectar la validez de los resultados estadísticos.
- **IBEX-35 (ibex_close):** Índice bursátil de referencia en el mercado de valores español, compuesto por las 35 empresas con mayor liquidez que cotizan en las bolsas de valores de España.
- **Deuda Pública (% del PIB) (deuda_perc_pib):** Porcentaje que representa la deuda total del sector público de un país en relación con su Producto Interno Bruto (PIB).
- **PIB Trimestral Per Cápita (pib_trim_per_capita):** Indicador económico que mide el valor promedio de bienes y servicios producidos por persona en un país en un trimestre, ajustado por la población.
- **Prima de Riesgo (prima):** Diferencial entre la rentabilidad de los bonos de un país y los de referencia, como los bonos alemanes.
- **Tasa de Desempleo (tasa_desempleo):** Porcentaje de la población activa que se encuentra sin empleo y busca trabajo activamente.
- **MAE (Mean Absolute Error):** Métrica de evaluación que calcula el promedio de las diferencias absolutas entre los valores predichos y los valores reales.
- **MAPE (Mean Absolute Percentage Error):** Métrica que mide el error absoluto promedio como un porcentaje de los valores reales.
- **MSE (Mean Squared Error):** Métrica que calcula el promedio de los cuadrados de los errores, penalizando más severamente los errores grandes.

- **RMSE (Root Mean Squared Error):** Raíz cuadrada del MSE, que proporciona una métrica de error en las mismas unidades que la variable objetivo.
- **SNARIMAX:** Modelo de series temporales que combina componentes autorregresivos, de promedios móviles y estacionales, y que puede incorporar factores exógenos.
- **Holt-Winters:** Técnica de modelado de series temporales que extiende la suavización exponencial para capturar patrones estacionales, de tendencia y nivel en los datos
- **Series Temporales:** Conjunto de datos ordenados cronológicamente que se analizan para identificar patrones y realizar predicciones futuras.
- **Preprocesamiento:** Parte inicial de un proyecto con datos que incluye tareas como la extracción, limpieza, transformación y estandarización de datos para garantizar que estén en un formato consistente y adecuado para el análisis y la modelización.
- **EDA (Exploratory Data Analysis):** Técnica para analizar datos de manera exploratoria, identificando patrones, relaciones y características clave.
- **PostgreSQL:** Sistema de gestión de bases de datos relacional y de código abierto utilizado para almacenar y manejar grandes volúmenes de datos.
- **ETL (Extract, Transform, Load):** Proceso que implica extraer datos de diversas fuentes, transformarlos en un formato adecuado y cargarlos en un sistema de almacenamiento o base de datos.

7. Bibliografía

1. Akhavanpour, M., (2024). *Adaptive model selection in stock market prediction: A modular and scalable Big Data analytics approach*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcgiclfindmkaj/https://scholar.uwindsor.ca/cgi/viewcontent.cgi?article=10159&context=etd> [Consulta: 2/10/2024]
2. Álvarez, C., (2024). *¿Qué son los criterios ESG ('environmental, social and governance')?* Recuperado de: <https://www.bbva.com/es/sostenibilidad/que-son-los-criterios-esg-environmental-social-and-governance-y-por-que-son-importantes-para-los-inversores/> [Consulta: 5/10/2024]
3. Appice, A., et al. (2023). *DARWIN: An online deep learning approach to handle concept drifts in predictive process monitoring*. Recuperado de: <https://www.sciencedirect.com/science/article/abs/pii/S0952197623006450> [Consulta: 2/10/2024]
4. Aragon, F., (2017). *Series temporales*. Recuperado de: <https://github.com/FrancisArgnR/SeriesTemporalesEnCastellano> [Consulta: 05/10/2024]
5. Bobbitt, Z., (2021). *Augmented Dickey-Fuller Test in Python (With Example)*. Recuperado de: <https://www.statology.org/dickey-fuller-test-python/> [Consulta: 4/10/2024]
6. Bookmap, (2023). *Adaptive algorithms in modern trading: The power of advance visualization*. Recuperado de: <https://bookmap.com/blog/adaptive-algorithms-in-modern-trading-the-power-of-advanced-visualization> [Consulta: 4/10/2024]
7. Cava, A., (2015). *Tipo de cambio y mercado de valores: estudio para el IBEX 35*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcgiclfindmkaj/https://repositorio.comillas.edu/rest/bitstreams/7251/retrieve> [Consulta: 2/10/2024]
8. Chen, L., (2020). *Stock price prediction using adaptive time series forecasting and Machine Learning algorithms*. Recuperado de: <https://escholarship.org/uc/item/0zp9s76c> [Consulta: 2/10/2024]
9. Cisneros, F., (2014). *Análisis de las variables que han influido en la evolución del IBEX 35 desde marzo de 2012 a septiembre de 2013*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcgiclfindmkaj/https://repositorio.comillas.edu/rest/bitstreams/460/retrieve> [Consulta: 2/10/2024]
10. Datos macro. (2024). *Deuda pública de España*. Recuperado de: <https://datosmacro.expansion.com/deuda/espana> [Consulta: 5/10/2024]
11. Datos macro. (2024). *España - Gasto público*. Recuperado de: <https://datosmacro.expansion.com/estado/gasto/espana> [Consulta: 2/10/2024]
12. Datos macro. (2024). *Letras del tesoro a 3 meses*. Recuperado de: <https://datosmacro.expansion.com/deuda/espana/tesoro/letras-3-meses> [Consulta: 4/10/2024]
13. Datos macro. (2024). *PIB de España – Producto Interior Bruto*. Recuperado de: <https://datosmacro.expansion.com/pib/espana> [Consulta: 4/10/2024]
14. Datos macro. (2024). *Tasa de desempleo*. Recuperado de: <https://datosmacro.expansion.com/paro/espana> [Consulta: 1/10/2024]

15. Datos macro. (2024). *Tipos del BCE – Banco Central Europeo*. Recuperado de: <https://datosmacro.expansion.com/tipo-interes/zona-euro> [Consulta: 4/10/2024]
16. El, (2024). *Modelo Markowitz: cómo maximizar rentabilidad y minimizar riesgos en tu cartera de inversión*. Recuperado de: <https://www.estrategiasdeinversion.com/herramientas/diccionario/mercados/modelo-de-markowitz-t-240> [Consulta: 2/10/2024]
17. Euribor Rates. (2024). *Tipos de interés del BCE*. Recuperado de: <https://www.euribor-rates.eu/es/tipo-de-interes-del-bce/> [Consulta: 4/10/2024]
18. Gama, J., et al. (2018). *A survey on concept drift adaptation*. Recuperado de: <https://dl.acm.org/doi/10.1145/2523813> [Consulta: 2/10/2024]
19. Gómez, M., (2024). *Las compras vuelven al IBEX 35 a la espera del BCE*. Recuperado de: <https://www.finanzas.com/ibex-35/las-compras-vuelven-al-ibex-35-a-la-espera-del-bce.html> [Consulta: 2/10/2024]
20. Hulten, G., et al., (2001). *Mining time-changing data streams*. Recuperado de: chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://citeseerx.ist.psu.edu/document?repid=rep1&type=pdf&doi=edf21eb4db4a9abdab0648f4d416dedce2efc6db [Consulta: 2/10/2024]
21. Huotari, T., et al. (2020). *Deep Reinforcement Learning Agent for S&P 500 stock selection*. Recuperado de: <https://www.mdpi.com/2075-1680/9/4/130> [Consulta: 2/10/2024]
22. IIC, (2024). *Big Data en bolsa, una inversión segura*. Recuperado de: <https://www.iic.uam.es/innovacion/big-data-en-bolsa/> [Consulta: 4/10/2024]
23. Inflation. (2024). *Inflación histórica España inflación IPC*. Recuperado de: <https://www.inflation.eu/es/tasas-de-inflacion/espana/inflacion-historica/ipc-inflacion-espana.aspx> [Consulta: 1/10/2024]
24. Investing. (2024). *Prima de riesgo*. Recuperado de: <https://es.investing.com/rates-bonds/de-10y-vs-es-10y-historical-data> [Consulta: 1/10/2024]
25. Jiménez, C., (2020). *Análisis y aplicación de data stream mining en mercados financieros*. Recuperado de: chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://oa.upm.es/63097/1/TFG_CARLOS_JIMENEZ_MARTIN.pdf [Consulta: 2/10/2024]
26. Kim, H., et al., (2022). *Stock market prediction based on adaptive training algorithm in machine learning*. Recuperado de: <https://www.tandfonline.com/doi/full/10.1080/14697688.2022.2041208?needAccess=true> [Consulta: 1/10/2024]
27. Lanseros, M., (2018). *Aplicación del modelo de 3 factores de Fama y French a las empresas del IBEX 35*. Recuperado de: chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://uvadoc.uva.es/bitstream/handle/10324/34248/TFG-E-548.pdf?sequence=1&isAllowed=y [Consulta: 2/10/2024]
28. Li, Y., (2019). *80% of the stock market is now on autopilot*. Recuperado de: <https://www.cnbc.com/2019/06/28/80percent-of-the-stock-market-is-now-on-autopilot.html> [Consulta: 4/10/2024]

29. Lu, J., et al. (2018). *Learning under concept drift: A review*. Recuperado de: <https://ieeexplore.ieee.org/abstract/document/8496795> [Consulta: 2/10/2024]
30. Medarde, N., (2014). *El modelo de tres factores de Fama y French aplicado al mercado español*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://repositorio.comillas.edu/rest/bitstreams/2763/retrieve> [Consulta: 2/10/2024]
31. Numxl, (2024). *Prueba Dickey-Fuller (DF)*. Recuperado de: https://numxl.com/es/blogs/prueba-dickey-fuller-aumentada/?srsltid=AfmBOopEJAcmJmMDOADX61xjDugiarDH4B0Muh_zJg5ED1Wo_0Fr2Tk4 [Consulta: 2/10/2024]
32. River, (2023). *Basic concepts*. Recuperado de: <https://riverml.xyz/0.22.0/introduction/basic-concepts/> [Consulta: 3/10/2024]
33. River, (2023). *Holt Winters*. Recuperado de: <https://riverml.xyz/dev/api/time-series/HoltWinters/> [Consulta: 4/12/2024]
34. River, (2023). *Metrics*. Recuperado de: <https://riverml.xyz/0.22.0/api/metrics/base/Metrics/> [Consulta: 4/12/2024]
35. River, (2023). *SNARIMAX*. Recuperado de: <https://riverml.xyz/0.22.0/api/time-series/SNARIMAX/> [Consulta: 4/12/2024]
36. Rúa-Figueroa, M., (2021). *How the IBEX 35 reacts to the announcements of the macroeconomic data*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://repositorio.unican.es/xmlui/bitstream/handle/10902/23043/RUAFIGUEROARODRIGUEZMARCOS.pdf?sequence=1&isAllowed=y> [Consulta: 2/10/2024]
37. Sklearn, (2024). *PCA*. Recuperado de: <https://scikit-learn.org/1.5/modules/generated/sklearn.decomposition.PCA.html> [Consulta: 4/12/2024]
38. Sklearn, (2024). *RandomForestRegressor*. Recuperado de: <https://scikit-learn.org/dev/modules/generated/sklearn.ensemble.RandomForestRegressor.html> [Consulta: 4/12/2024]
39. Sklearn, (2024). *RFE*. Recuperado de: https://scikit-learn.org/dev/modules/generated/sklearn.feature_selection.RFE.html [Consulta: 4/12/2024]
40. Statsmodels, (2023). *Statsmodels.graphics.tsaplots.plot_acf*. Recuperado de: https://www.statsmodels.org/dev/generated/statsmodels.graphics.tsaplots.plot_acf.html [Consulta: 4/12/2024]
41. Statsmodels, (2023). *Statsmodels.graphics.tsaplots.plot_pacf*. Recuperado de: https://www.statsmodels.org/stable/generated/statsmodels.graphics.tsaplots.plot_pacf.html [Consulta: 4/12/2024]
42. Statsmodels, (2023). *Statsmodels.regression.linear_model.OLS*. Recuperado de: https://www.statsmodels.org/dev/generated/statsmodels.regression.linear_model.OLS.html [Consulta: 4/12/2024]
43. Statsmodels, (2023). *Statsmodels.stats.diagnostic.het_breuschpagan*. Recuperado de: https://www.statsmodels.org/dev/generated/statsmodels.stats.diagnostic.het_breuschpagan.html [Consulta: 4/12/2024]

44. Statsmodels, (2023). *Statsmodels.stats.diagnostic.het_white*. Recuperado de: https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.het_white.html [Consulta: 4/12/2024]
45. Statsmodels, (2023). *Statsmodels.tsa.seasonal.seasonal_decompose*. Recuperado de: https://www.statsmodels.org/stable/generated/statsmodels.tsa.seasonal.seasonal_decompose.html [Consulta: 4/12/2024]
46. Statsmodels, (2023). *Statsmodels.tsa.stattools.adfuller*. Recuperado de: <https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.adfuller.html> [Consulta: 4/12/2024]
47. Statsmodels, (2023). *Statsmodels.tsa.stattools.ccf*. Recuperado de: <https://www.statsmodels.org/stable/generated/statsmodels.tsa.stattools.ccf.html> [Consulta: 4/12/2024]
48. Suárez, A., et al. (2019). *Incremental market behavior classification in presence of recurring concepts*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://e-archivo.uc3m.es/rest/api/core/bitstreams/d152aff0-89d4-459a-b86c-9e78cdf06eee/content> [Consulta: 2/10/2024]
49. Sujit, S., (2015). *Do you use coeficient of variation to determine forecastability?* Recuperado de: <https://blog.arkieva.com/do-you-use-coefficient-of-> [Consulta: 02/10/2024]
50. Tapia, M., (2018). *Análisis de la economía española y su relación con el IBEX 35*. Recuperado de: <chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://uvadoc.uva.es/bitstream/handle/10324/30959/TFG-N.940.pdf> [Consulta: 2/10/2024]
51. UNIR, (2022). *¿Qué es la ratio Sharpe y qué mide?* Recuperado de: <https://www.unir.net/revista/empresa/ratio-sharpe/> [Consulta: 2/10/2024]
52. Villalba, R., (2020). *Series temporales con ARIMA I*. Recuperado de: <http://enrdados.net/post/series-temporales-con-arima-i/> [Consulta: 08/10/2024]
53. Villavicencio, J. (2010). *Introducción a series de tiempo. Puerto Rico*. Recuperat de: https://d1wqtxts1xzle7.cloudfront.net/38458362/manual_intro_series_tiempo-libre. [Consulta: 3/10/2024]
54. Yagoo Finance. (2024). *EUR/USD*. Recuperado de: <https://finance.yahoo.com/quote/EURUSD%3DX/> [Consulta: 2/10/2024]
55. Yagoo Finance. (2024). *IBEX35*. Recuperado de: <https://es.finance.yahoo.com/quote/%5EIBEX/history/> [Consulta: 3/10/2024]

8. Anexos

```
def create_snarimax_model():
    model = time_series.SNARIMAX(
        p=1,
        d=1,
        q=0,
        m=12,
        sp=3,
        sq=6,
        regressor=(
            preprocessing.StandardScaler() |
            linear_model.LinearRegression(
                intercept_init=110,
                optimizer=optim.SGD(0.01),
                intercept_lr=0.3 )))
    return model
```

Código 3: Función para crear un modelo SNARIMAX

```
winters_w3_kswin = time_series.HoltWinters(
    alpha=0.3,
    beta=0.1,
    gamma=0.6,
    seasonality=12,
    multiplicative=True)
```

Código 4: Configuración del algoritmo de Holt Winters

Selección de variables					
Factor	RFR	RFE	PCA	Correlación Pearson	Seleccionada
ibex_volume	No	No	Sí	No	No
deuda_perc_pib	Sí	Sí	Sí	No	Sí
gasto_perc_PIB	No	No	Sí	No	No
pib_trim_per_capita	Sí	Sí	No	Sí	Sí
var_pib	No	No	No	No	No
var_anual_pib	No	No	Sí	No	No
tasa_desempleo	Sí	Sí	Sí	Sí	Sí
tie	No	No	Sí	No	No
ipc	No	No	No	No	No
prima	Sí	Sí	Sí	Sí	Sí
eurusd_close	No	Sí	No	Sí	No
tim	No	No	No	No	No

Tabla 9: Resultados de la selección de variables

Meses	ibex_close	deuda_perc_pib	pib_trim_per_capita	prima	tasa_desempleo
1	1.00	1.00	1.00	1.00	1.00
2	1.00	1.00	1.00	1.01	1.00
3	1.00	1.00	1.00	0.99	1.00
4	1.00	1.00	1.00	1.00	1.00
5	1.00	1.00	1.00	1.00	1.00
6	1.00	1.00	1.00	1.00	1.00
7	1.00	1.00	1.00	0.99	1.00
8	1.00	1.00	1.00	1.00	1.00
9	1.00	1.00	1.00	1.00	1.00
10	1.00	1.00	1.00	1.01	1.00
11	1.00	1.00	1.00	1.00	1.00
12	1.00	1.00	1.00	0.99	1.00

Tabla 10: Resultados del Índice de Variación Estacional